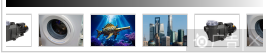
昼夜光影变幻


【产发业上】神经常微分方程与液态神经网络

理财小课堂
+订阅
2.1万 文章 3603万 总阅读
查看TA的文章>

2025-03-06 08:17 发布于：山西省

神经常微分方程：在机器学习国际顶会NeurIPS 2018上，Chen等人发表的论文《Neural Ordinary Differential Equations》获得了大会的最佳论文奖。简单来说，一个常见的ResNet网络通常由多个形如h_{t+1}=f(h_t,θ_t)+h_t的残差结构所组成。在常规求解中，需计算出每一个残差结构中最能拟合训练数据的网络参数。而该论文提出，假设当ResNet网络中的残差结构无限堆叠时，则每一个残差结构的参数都可以通过求解同一个常微分方程来获得。

液态神经网络：基于上述工作，来自麻省理工学院的Ramin Hasani等人，创新性地以常微分方程的形式描述循环神经网络的隐藏状态变化，提出了一类被称之为液态神经网络的模型，这些研究成果被发表在《Nature：Machine Intelligence》等国际顶级期刊上。此类模型通过将离散时间步长的循环神经网络“连续化”，使模型具有更好的表征能力。与此同时，稀疏的网络结构带来了更高的计算效率，并且使得模型在异常输入时可以保持优秀的稳健性。这些特性有望使其超过传统的循环神经网络，在量化选股中展现出更优秀的能力。

实证分析：本研究在保持输入数据、目标函数等非主干网络结构完全一致的情况下，将LTC、NCP（LTC）、CFC、NCP（CFC）四个液态神经网络类模型，与最具代表性的常规循环神经网络GRU进行对比。从结果上来看，主要有以下几个结论：

（1）液态神经网络能够显著降低模型复杂度和显存依赖，以大幅低于传统网络的计算消耗来得到同等结果。具体而言，当同样的数据量在GRU中需要120Gb显存时，在LTC和NCP（LTC）中需约80Gb显存，而在CFC和NCP（CFC）中仅需约6Gb显存，仅为GRU所需显存的5%（如右图3所示），这为在有限资源的情况下训练大数据模型提供了可能性；

（2）尽管各个模型的输入数据和目标函数等非主干网络结构一致，但由于主干网络本身所带来的差异使得最终因子呈现出一定的差异化，因子的相关系数在 0.69~0.82 之间，说明不同的模型能够在相同的数据中学习到不一样的价量特征；

（3）通过分年度的表现统计与对比，上述观点得到了进一步验证，且使用NCP网络结构通常能取得更好的性能。

风险提示：（1）本文所述模型用量化方法通过历史数据统计、建模和测算完成，所得结论与规律在市场政策、环境变化时存在失效风险；（2）本文策略在市场结构及交易行为改变时有可能存在失效风险；（3）因量化模型不同，本文提出的观点可能与其他量化模型结论存在差异。

一、神经常微分方程与液态神经网络

首赞
抢首评 评论
收藏
分享
扫码打开手机搜狐网
无需下载APP
精彩内容随时看

大家都在搜：人民的小事就是我们的大

球鞋专卖

关于房产的律

自动增压泵价格

整车起运!汽车托运
热门精选
《色.戒》里汤唯梁朝伟到底是真干假干?
断路器机械特性监测装置实现开关柜智能运...
撤销学位不到一浅浅再迎两大噩
关系性AI架构创新白皮书——重构人机共生...
明月湖7个研究项选市级科技攻关

投资培训

二手相机出售

好玩的回合制网游

深圳市公司
24小时热文
1 阿根廷赛后亮马岛横幅闯或遭国际足联处罚
13万 阅读

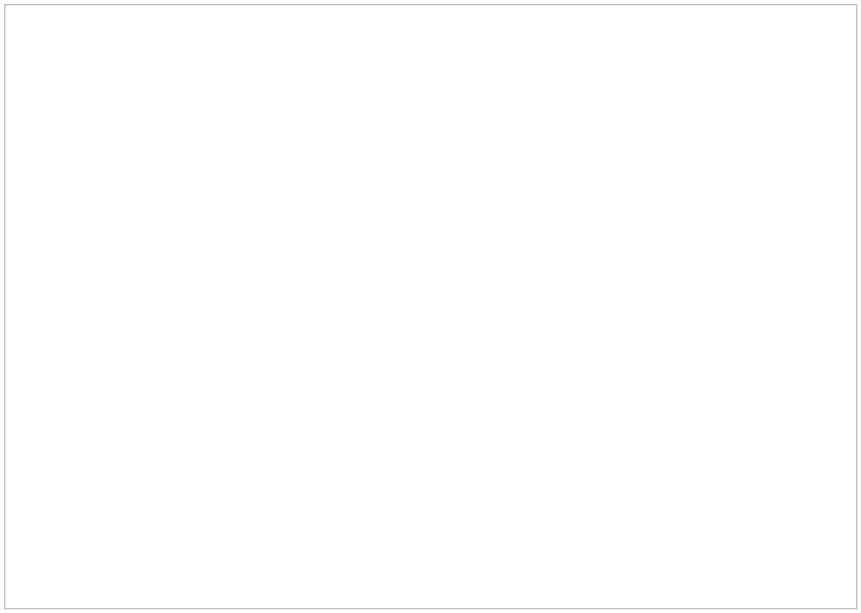
收益的复杂非线性关系，不断更新自身参数，进而展现出优秀的选股能力。

用于提取数据特征的主干网络（Backbone），是这些基于深度学习的量化选股模型的关键构成。尽管各种量化选股模型的数据输入、目标函数等存在差异，但其用于数据特征提取的主干网络通常为循环神经网络（如RNN、LSTM、GRU）、卷积神经网络（CNN、TCN）、Transformer等常规模型。不同的量化选股模型更多地聚焦于各类细节上的优化，在主干网络的使用上并未有太多的创新。因此，本文将聚焦于一类新的主干网络，研究其在量化选股模型中的应用。

（一）神经常微分方程

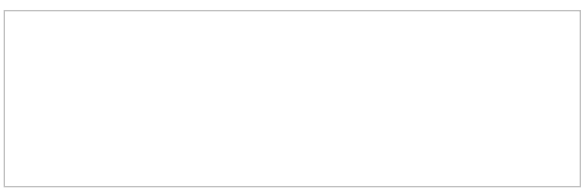
ResNet（残差网络，Residual Network）是由微软研究院的何恺明等人在2015年提出的一种深度卷积神经网络架构。它通过引入残差学习（Residual Learning）的概念，解决了传统深度神经网络中因层数过深导致的退化问题（即随着网络加深，训练误差反而增大），成为深度学习领域的里程碑式工作。

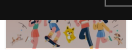
在机器学习国际顶会NeurIPS 2018上，Chen等人发表的论文《Neural Ordinary Differential Equations》获得了大会的最佳论文奖，介绍了以下新颖工作。



如果将某个残差块的输入记为h_t，输出记为h_{t+1]，残差块的主干网络函数记为f，参数记为θ_t，那么这个残差块的前向传播可以由以下公式表示：

以数学角度看，如果假设t是连续的，h(t)是一个随t变化的函数，那么残差网络可以认为是在给定t和h(t)时，输出t+1时刻h的值。如果选择更短的步长，并使之趋于极限，就得到了一个神经常微分方程：




180万 阅读


中疾控：新冠疫情已演变
呼吸道传染病
46万 阅读


英媒批贝林厄姆赛后行为
育精神 可能被禁赛
28万 阅读


行为艺术照
艺术照
7115阅读



逾期协商还款

搜狐号

北京日报 钢结构全面封顶！首都医科
新校区（校本部）项目最新

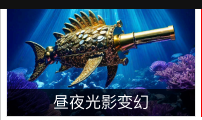
搜狐网地... 87分钟 津沧高速改扩建“老
移除

洞庭湖边... 【“阅享”领读】悦故事栏目
106期《特别的气象员》

中部城市... 市市场监管局集中销毁12吨
药品

中原新闻网 601个药品通过2026年医保
调整形式审查

大西北消... 毕业了档案转去哪、怎么查
文讲清



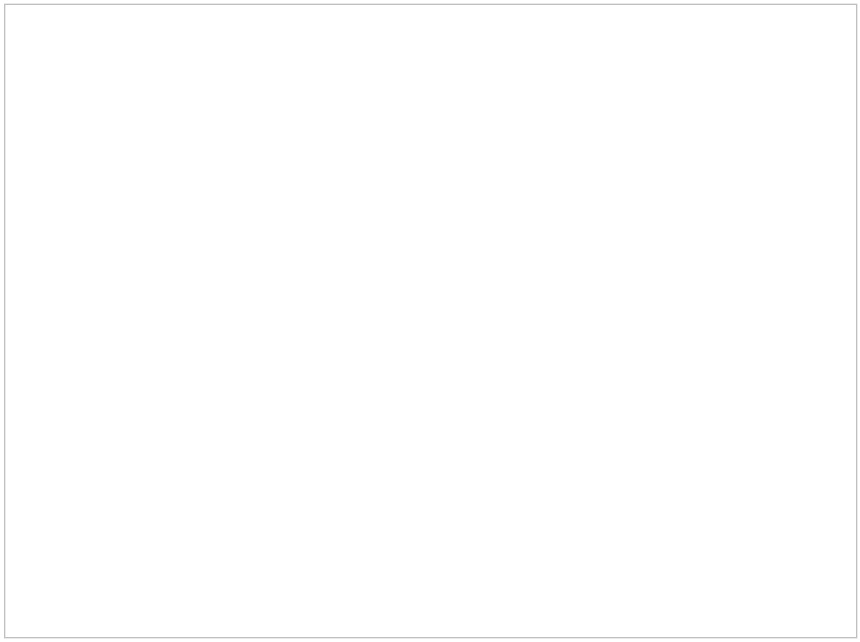




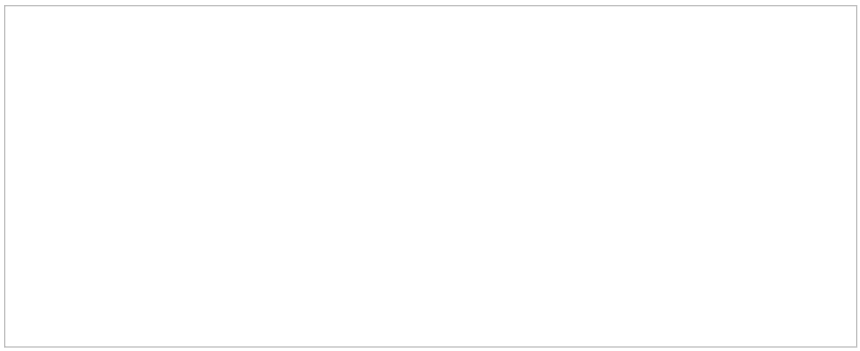


残差块的参数θ_t并不断递推。而在神经常微分方程定义下，只需要对同一个神经常微分方程进行求解，没有隐藏状态递推的步骤。给定初值条件h_0，即初始输入张量，就可以通过各类微分方程求解器求解得到h_T。

由于神经微分方程网络在前向传播时需要利用微分方程求解器得到最终输出，那么如何通过反向传播来执行参数更新呢？作者在论文中采用了一种称为伴随灵敏度的方法（Adjoint Sensitivity Method，Pontryagin et al., 1962），如下图所示。此方法通过求解另一个常微分方程来计算损失对于参数的梯度，优点在于降低了常数空间的内存需求，但代价是牺牲了部分精确性，具体算法可以参考原论文。



基于经典的图像分类数据集MNIST（LeCun et al., 1998），作者对ODE-Net和ResNet等网络进行了对比，如下表所示。从表中可以看出，ResNet的复杂度与卷积块的数量L直接相关，而ODE-Net的复杂度仅与神经常微分方程相关因此为恒定值。在同等测试误差的情况下，ODE-Net参数量和计算消耗更小。



（二）从循环神经网络到液态神经网络

由于股票数据具有天然的时间序列特性，许多研究者都将基于深度学习的量化选股视作多变量时间序列预测问题。循环神经网络（Recurrent Neural Network，RNN）作为一类强大的深度学习模型，可以建模序列化输入之间的时序关系，是此类问题的主要解决方案之一。

（Gated Recurrent Units，GRU）等多种形式的循环神经网络被提出，并在量化选股上展现出了不俗的表现，但它们本质上仍然遵循着循环神经网络以时间步为单位处理输入数据的思想。本文在此以简单循环神经网络为例进行说明。



循环神经网络以一组序列数据作为输入，即X=[x_1,x_2,...,x_T]，其中，x_t ∈ R^h，下标代表了时间步的顺序。对于每一个时间步，模型会接受上一个时间步的隐藏状态h_{t−1} ∈ R^h与当前时间步的输入x_t，输出当前时间步更新后的隐藏状态h_t=f(x_t,h_{t−1},θ_1)与当前时间步的最终输出y_t=g(h_t,θ_2)。其中θ_1和θ_2是可学习的模型参数，在所有时间步上共享。通过这种方法，每个时间步的输出都由当前的输入及更早时间步的输入所确定，从而可以综合时序上的信息进行特征提取。

应用在量化选股中，循环神经网络通常用来捕捉个股时序数据上的变化关系，以日频数据为例，T通常代表个股T个交易日的回看窗口，x_t代表单个交易日的特征向量，例如某个交易日里某只股票的开盘价、最高价、最低价、收盘价、成交量、成交金额等数据。将数据输入模型后，通常选择最后一个时间步的隐藏状态作为输出，再使用其它的网络模型，如前馈神经网络（Feedforward Neural Network）对其进行降维，用降维后的结果来拟合未来收益率标签。

以上提到的循环神经网络模型都是时间离散的，这意味着对于隐藏状态h_t，总是在离散时间步进行更新。在最初h_0初始化后，每个时间步的信息被依次输入进循环神经网络，一步步将隐藏状态h_t更新到最后一个时间步T，然后针对进行h_T后续的预测。可以将每个时间步的隐藏状态更新公式改写为：

此公式本质上说明了循环神经网络是在利用模型来表征不同时间步隐藏状态的差分值，即在模型训练过程中，神经网络函数f(,θ)在不断学习隐藏状态的差分h_t−h_{t−1}应该是多少，并基于此逐步对h进行修改。然而，如果将循环神经网络的思路继续拓展，与其让模型学习离散时间间隔下隐藏状态的差分值，为何不将其“连续化”，直接让模型学习连续时间下任意时刻隐藏状态的微分值呢?

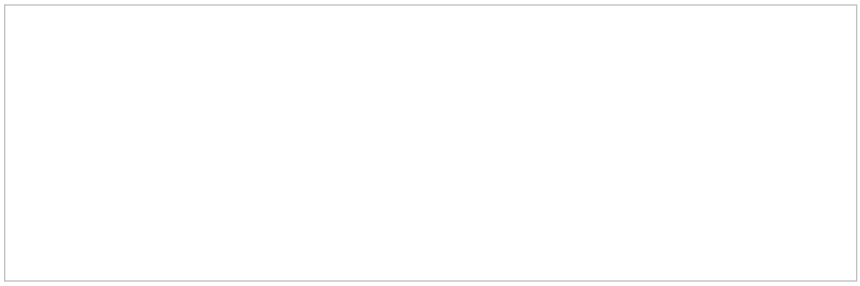
在这个思路下，来自麻省理工学院的Ramin Hasani等人，创新性地以微分方程的形式描述循环神经网络的隐藏状态变化，提出了一类被称之为液态神经网络的模型，包括液态时间常数网络（LTC），神经电路策略网络（NCP）与闭式连续时间神经网络（CFC），这些研究成果被发表在《Nature：Machine Intelligence》等国际顶级期刊上。此类模型通过将离散时间步长的循环神经网络“连续化”，使模型具有更好的表征能力。与此同时，稀疏的网络结构带来了更高的计算效率，并且使得模型在异常输入时可以保持优秀的稳健性。这些特性有望使其超过传统的循环神经网络，在量化选股中展现出更优秀的能力。

（三）液体时间常数网络

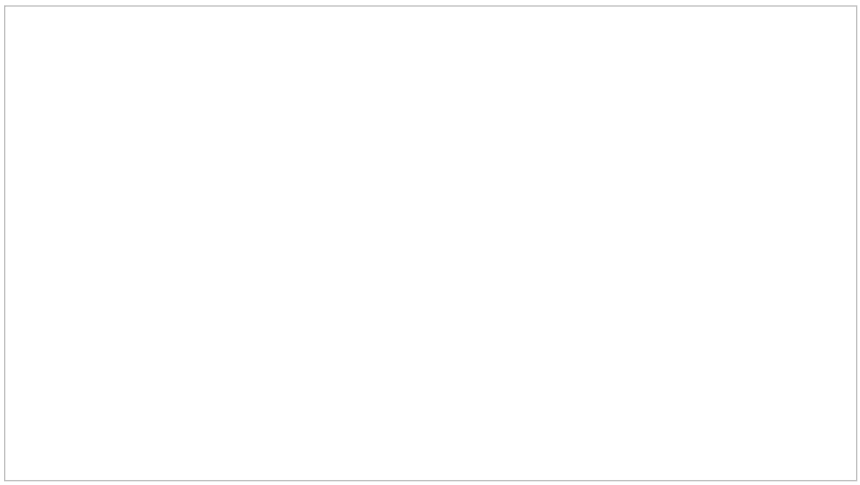
一种稳定的连续时间循环神经网络，即液态时间常数网络（Liquid Time-constant Networks，LTC），LTC相比于此前提出的循环神经网络和ODE-Net有着更强大的表达能力。其公式如下：

在此处，h(t) ∈ R^N代表某个时刻循环神经网络的隐藏状态，x(t) ∈ R^M代表某个时刻的输入，f为神经网络模型，τ、θ和A为参数，公式中所有的运算都是逐元素进行的。如同神经常微分方程一样，上述公式定义了不同时间点下循环神经网络的隐藏状态h变化的导数。

为什么LTC要这么设计呢？首先，以微分形式表达循环神经网络的方法继承了神经常微分方程的思路，为隐藏状态的变化带来了更大的灵活性。其次，LTC的设计受到了生物学的启发。作者通过研究小型微生物神经元的电位动态，利用LTC对非线性的突触活动进行了模拟。以隐藏状态的某一个隐藏神经元为例：



通过以上LTC微分方程，可以将S(t)视为神经元k在某个时刻所接收到的突触电流，S(t)通过乘积的形式引入了一定非线性，增强了模型表达能力。-h_k(t)/τ代表神经元自身电位随时间衰减，τ是衰减的时间常数，可以控制衰减的速率，这就是论文标题中的“时间常数”的数学意义。



除了定义LTC网络结构，论文中还介绍了一种结合了隐式欧拉法和显式欧拉法的常微分方程求解器，用来计算LTC的前向传播步骤。简单来说，首先将微分方程离散化，在给定t与h(t)时，近似计算h(t+Δt)的值。

如果以t时刻的微分值近似代替h在Δt上的斜率，那么就可以通过下式直接近似得到h(t+Δt)，这就是显式欧拉法。

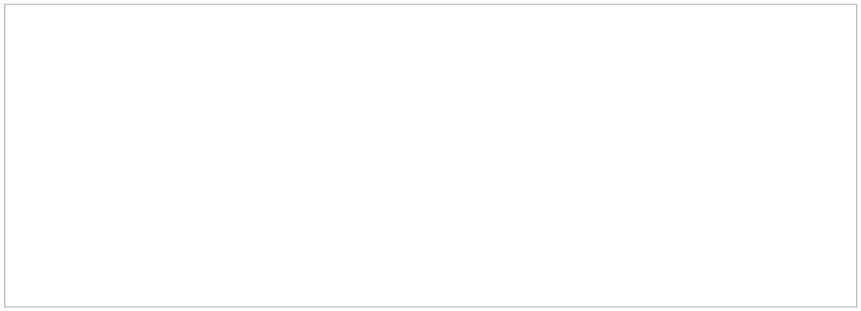
如果以t+Δt时刻的微分值近似代替h在Δt上的斜率，那么就可以通过解下式方程近似得到h(t+Δt)，这就是隐式欧拉法。

式与隐式欧拉法，使用下述公式避免了隐式欧拉法的近似求解方程，但是仍保留了一定的稳定性，使其同时兼顾了速度和准确性：

解得：

上式给出了此微分方程求解器下，LTC的隐藏状态在小步长上的更新方式。

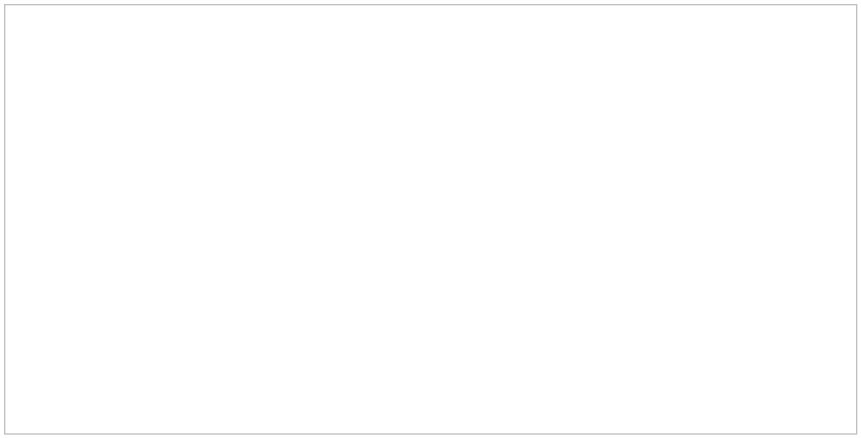
不同于神经常微分方程所使用的伴随方法进行参数更新，LTC仍然选择使用梯度反向传播的方法。从下图的对比可以看出，梯度反向传播相比伴随方法更为精确，但代价是需要消耗更多内存。具体的前向传播与参数更新算法步骤请参见原论文。



从论文中提供的实验数据中可以看到，LTC在大部分时间序列预测任务上相比其它循环神经网络模型展现出了5%到70%的性能提升，体现了其强大的预测能力。这使得本文研究开始探讨，LTC模型能否在量化选股策略上也表现优异?

（四）神经电路策略网络

在提出LTC后，原作者团队开始思考如何将LTC应用于现实世界的复杂任务中。2020年，作者在前序工作基础上，发表了论文《Neural Circuit Policies Enabling Auditable autonomy》。在该论文中，作者提出了一种受生物学启发的网络架构，称为神经电路策略（Neural Circuit Policies，NCP），并基于此成功将LTC应用于自动驾驶控制任务上。NCP网络架构如下图所示。



NCP在本质上是基于LTC设计的，其每一个神经元都可以视作一个LTC的隐藏状态。要将其详细说明，需要先以简单循环神经网络举例。不妨假设一个输入特征维度为2，隐藏状态维度为4的简单循环神经网络，如图6所示。

简单循环神经网络的隐藏状态更新公式可以写成下式，其中x_t ∈ R^2，h ∈ R^4：

假设f只是一个简单的激活函数嵌套线性层，如tanh，参数W_r ∈ R^{4*4}，W_i ∈R^{4*2}，μ ∈R^4，上式可改写为：

从图6中可以看出，简单循环神经网络每个隐藏状态神经元的更新来自于其余所有神经元以及自身的贡献，所有隐藏神经元之间组成了一个有向全连接图，并且节点自身成环。换言之，隐藏神经元更新需要接收到的输入信号为包括自己在内的所有神经元的信号，它们在网络内地位上是等价的。

对于以上述简单循环神经网络为基础结构的LTC，其结构与图6一致，区别在于每个隐藏神经元的更新是连续的，即它们时刻在变化，并且来自所有其它神经元（包括自身）的输入信号共同决定了当前隐藏神经元的变化速率与方向。其微分方程可以如下式表示。

其中tanh(W_rh(t)+W_ix(t)+μ)的第k个元素代表了计算隐藏神经元h_k的微分dh_k(t)/dt所需要接受的激活输入。在LTC中，由于每个神经元都会对其有贡献，所以其图像是全连接的。

NCP的提出灵感来自于秀丽隐杆线虫神经系统中独特的四层分层神经网络电路，其结构可参考图5中四种颜色的神经元。线虫首先通过感觉神经元接收环境观察结果。然后，神经信号被传递到中间神经元和命令神经元，由它们生成决策。最后，决策被传递给运动神经元来驱动肌肉。

作者仿照线虫的神经结构，设计了一系列NCP网络结构规则，在四层网络的基础上保证了神经元连接的随机性与稀疏性。作者利用随机概率方法来构建NCP，模仿了线虫的变异性，创建了一个整体性模型，同时在其中允许小的随机变化。与前文基于简单循环神经网络结构的LTC相比，NCP的所有隐藏状态不再以全连接的形式相连，而是变得十分稀疏，并且不同组的神经元有明确的“分工”，其示意图以及与LTC的对比可参考图6和图7。相比普通的循环神经网络，NCP网络可训练参数更少，模型更为紧凑。

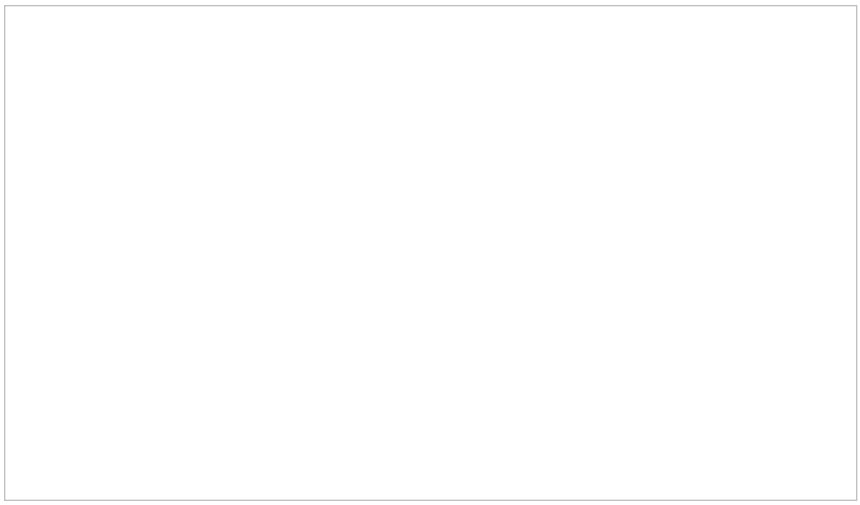
NCP是基于LTC所构建的，网络中的每个神经元都保持着连续的变化。但是与上述全连接的LTC相比，隐藏神经元的变化速率与方向不再受全部的输入神经元与隐藏神经元所影响，而是仅由存在节点输入的神经元所决定。

以一个稀疏的NCP网络的某个隐藏神经元i为例，假设它只有一个输入神经元j，那么其更新规则可以由下面的LTC微分方程给出。其中所有参数都是以生物学的形式定义的，τ_i=c_mi/g_ti表示神经元i的时间常数，C_mi表示模电容，x_leak_i表示静息电位，E_ij是定义突触极性的反转突触电位。

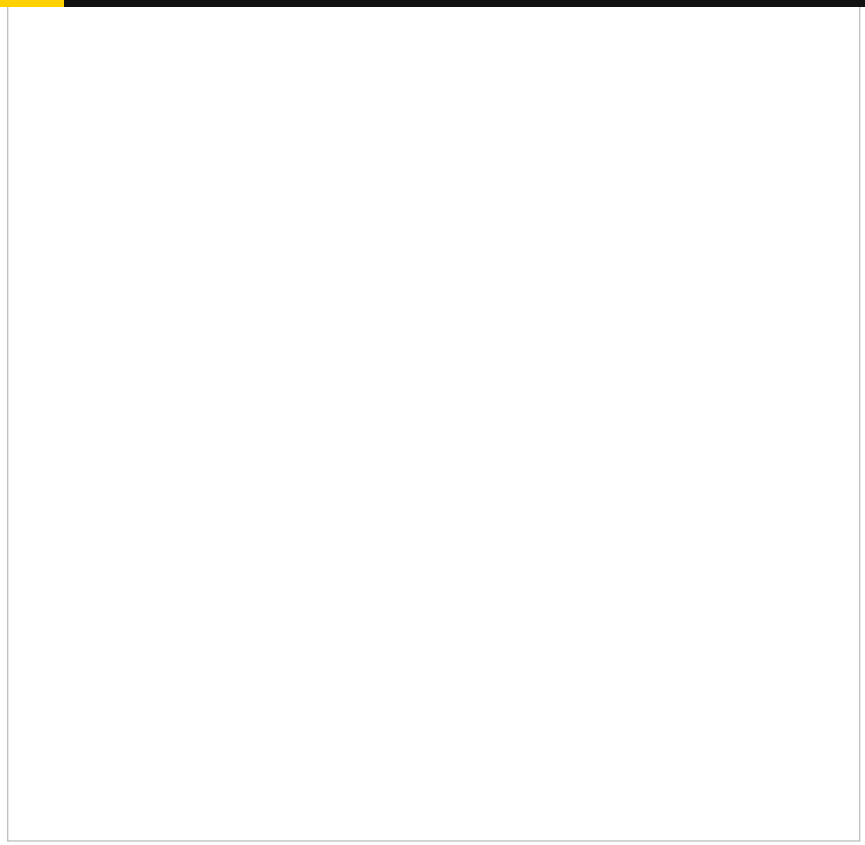
神经元与j对其有输入突触连接，所以这里的输入只包括j的神经信号。简单LTC可以视作一个全连接的NCP网络，每个隐藏神经元的输入突触都包含其它所有神经元以及它自身。

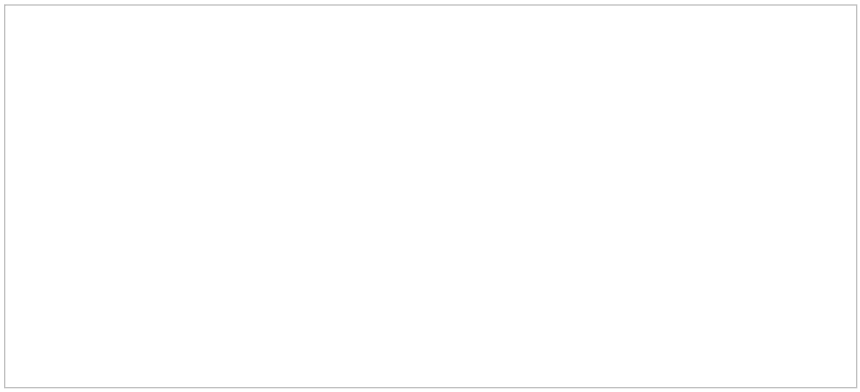
依照LTC中提出的半隐式欧拉法微分方程求解器，可以得到小步长上NCP网络隐藏神经元更新的公式，具体请参见原论文。

在量化选股中，由于每日股票特征可能存在异常变化，这些噪声通常无法被历史数据所解释，可能会诱导模型做出不可预期的决策。在此情况下，NCP模型的稳健性或许可以使其滤除某一时刻的噪声干扰，从而做出更可靠、更合理的决策。



NCP模型具有更少的可训练参数与更稀疏的网络结构，但却在自动驾驶中展示出了更优秀的表现。如下图9、10所示，作者在文中对比了NCP模型在自动驾驶任务中与其它模型的误差，可以看出NCP在样本外数据上具有接近LSTM的优秀表现，但其模型参数量显著更少。





最后，作者证明了NCP模型具有更优秀的可解释性。由于NCP模型的神经元基于仿生学设计，存在不同的“分工”，并且网络有着更少的神经元数量、更大的稀疏性，每个神经元的行为都由微分方程描述，所以可以更准确地分析单个神经元的动态。这使得研究人员可以分析不同神经元的神经状态和耦合灵敏度，在不同的环境下对比不同神经元对输出的贡献变化，进而理解网络是如何做出最终决策的。如果将这种可解释性推广到量化选股中，有望能够基于此分析在不同的市场环境下，NCP模型是如何做出决策的。

（五）闭式连续时间神经网络

在提出了LTC和NCP模型后，作者Ramin Hasani等人开始思考，尽管通过半隐式欧拉法微分方程求解器来近似求解隐藏状态的连续变化可以有效模拟隐藏神经元的动力学行为，但是此方法的缺点也很明显：首先，微分方程求解器的近似精度会成为限制模型表达能力的瓶颈；其次，当迭代步长很小、而神经元数量很多时，它会带来很大的计算成本。换言之，微分方程求解器难以在模型表达能力与计算速度上取得平衡。这一缺点在需要快速得到反馈的

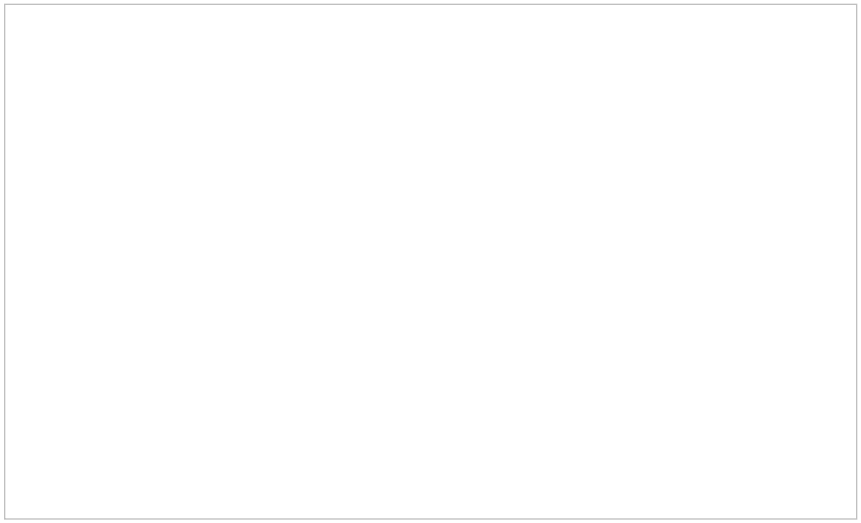
的微分方程是实现计算出闭式解（解析解）。

2022年，原作者团队发表了论文《Closed-form Continuous-time Neural Networks》。在该论文中，作者给出了一个在LTC模型中出现的微分方程的紧有界近似解，从而在模型计算中避免了复杂的微分方程数值求解。此外，论文还基于这一闭式解，构建了一个新的闭式连续深度神经网络模型（CFC），此模型在一系列实验中展现出了更低的计算复杂度和更优秀的性能。

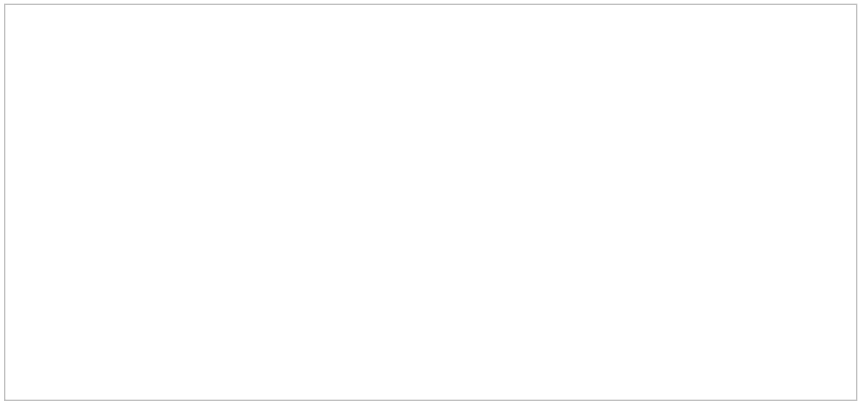
首先，对于LTC的微分方程：

作者在文中证明了在一定误差范围内，其闭式解可以近似表示为：

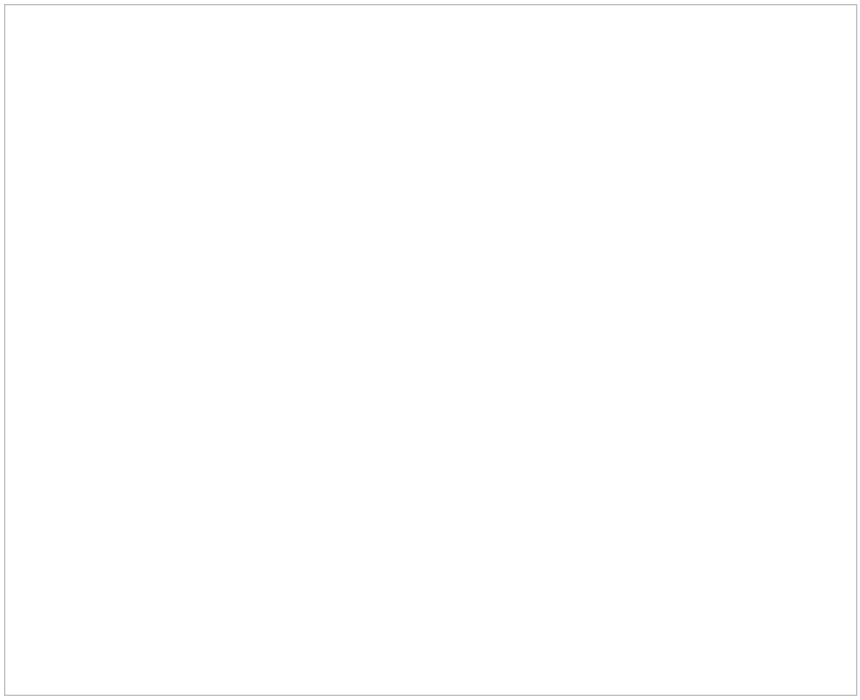
以上形式使得h(t)不需要经过复杂的微分方程求解器迭代得出，而是可以通过解析形式进行计算。在下图11中，作者通过实验证明了这一简单的近似闭式解可以很好的模拟LTC网络的隐藏神经元动态。这说明在大幅提高运算效率的前提下，此模型仍然具有良好的近似能力。

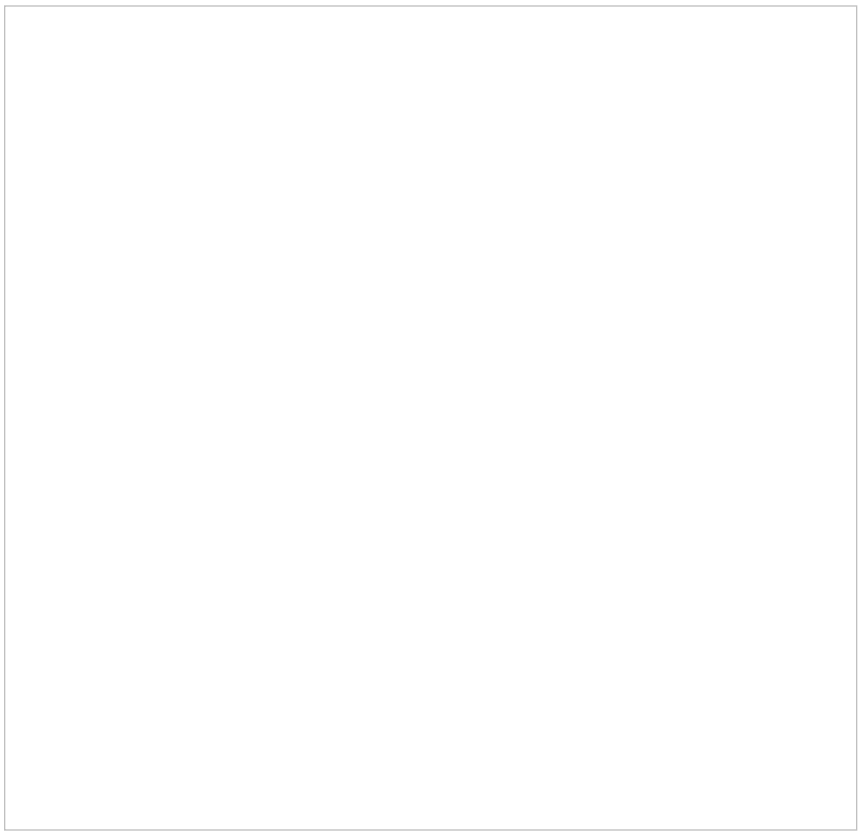


通过此闭式解，已经可以导出一个连续时间的神经网络模型。但是，这个模型仍然存在可训练性问题。例如随着t不断增大，公式中的指数项会以很快的速度收敛至0，从而使得隐藏状态趋于A。作者对此模型公式进行了一定优化，使得它可以被很好地训练。修改后的CFC网络如下式所示，示意图参见图12。为了避免符号混淆，此处x用代表隐藏状态，I代表输入，\sigma代表sigmoid函数，f、g、h代表三个可学习的网络，它们共享了前几层的主干网络。



二个网络可以视为任何神经网络实例，这使得CTC有很高的灵活性。





（六）小结

本文通过以上章节，综述了一类新颖的以神经常微分方程定义的连续时间网络模型，它们的共同特点是以神经常微分方程刻画了隐藏神经元在连续时间上的状态变化。最初的神经常微分方程提出了将离散状态“连续化”的思想，开创性的使用模型输出表征隐藏状态的微分。之后的LTC网络继承了这一思想，并使得网络更为稳定以及更具表达能力。此外作者还采用

NCP网络以LTC为基础，参考了线虫的生物学结构，设计了一种更为稀疏的模型组织方式，使得模型更为稳健，也更有可解释性。最后的CFC网络则是通过给出LTC微分方程的近似闭式解，避免了复杂的微分方程求解过程，极大提升了网络的效率。在某种程度上，以上所有模型都可以作为对传统循环神经网络的改进。在下文中，将通过实证分析探讨以上模型在量化选股策略中的应用。

二、实证分析

本研究在保持输入数据、目标函数等非主干网络结构一致的情况下，将LTC、NCP（LTC）、CFC、NCP（CFC）四个液态神经网络类模型，与最具代表性的常规循环神经网络GRU进行基准对比，具体如下。

（一）数据说明

选股范围：全市场

选股处理：剔除非上市、摘牌、ST/*ST、涨跌停板、上市未满1年股票

训练数据：全市场2008年1月～2016年12月

验证数据：全市场2017年2月～2019年11月（与训练数据间隔1个月防止数据暴露）

回测区间：2020年1月～2024年12月（与验证数据间隔1个月防止数据暴露）

分档方式：根据当期模型预测因子值，从大到小分为10档

回测路径：以多路径回测均值作为统计数据

调仓周期：每20个交易日，根据模型在t日的预测结果，以t+1日均价买入，t+1+n日均价卖出

交易费用：千分之三（卖出时收取），以下展示回测数据均为计费后的结果

（二）整体表现对比

常规循环神经网络GRU与四个液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）的整体表现对比如下表所示。整体而言，各个模型在RankIC和分组年化收益率指标上并未拉开明显差异。但液态神经网络特别是CFC与NCP（CFC）网络能够在取得同等表现的情况下，显著降低模型复杂度和显存依赖。具体而言，当同样的数据在GRU中需要120Gb显存时，在LTC和NCP（LTC）中需约80Gb显存，而在CFC和NCP（CFC）中仅需约6Gb显存，仅为GRU所需显存的5%，这为在有限资源的情况下训练大数据模型提供了可能性。

（三）相关性

常规循环神经网络GRU与四个液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）的因子相关性如下表所示。整体而言，尽管各个模型的输入数据和目标函数等非主干网络结构一致，但由于主干网络本身所带来的差异使得最终的因子呈现出一定的差异化，因子的相关系数在0.69~0.82之间，说明不同的模型能够在相同的数据中学习到不一样的价量特征。

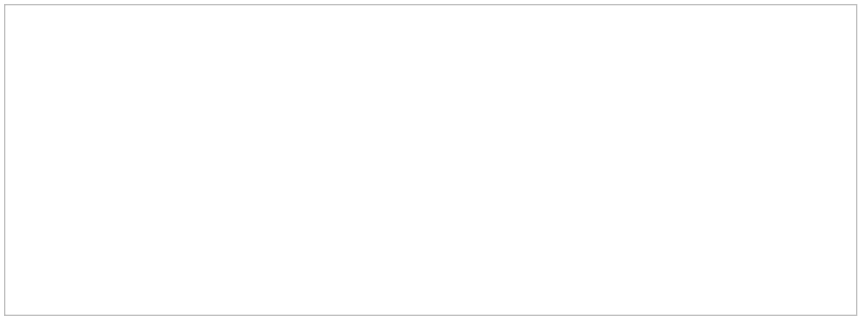
下图15-24、表6-10分别展示了常规循环神经网络GRU与四个液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）的样本外因子10分档表现、RankIC表现和分年度收益统计。从结果来看，液态神经网络确实能够以显著更少的参数和显存依赖，取得与GRU同等水平的选股表现，且使用NCP网络结构通常能取得更好的性能，这为在有限资源的情况下训练大数据模型提供了可能性。

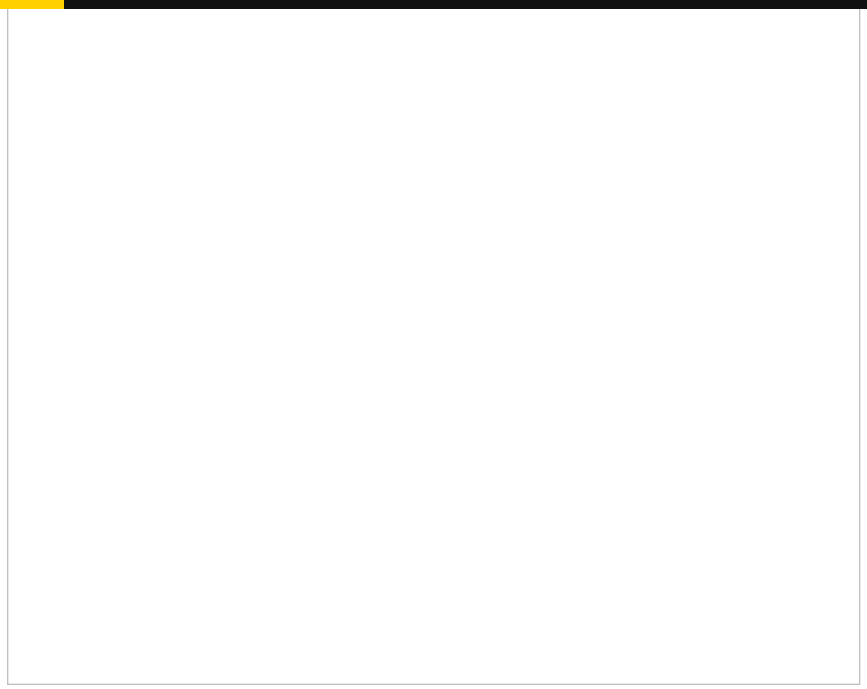
从多头收益来看，GRU在2020~2024年期间的年化收益率为24.21%，夏普比率为0.88；而液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）在同期的年化收益率分别为22.21%、24.38%、23.23%、23.65%，夏普比率分别为0.87、0.95、0.93、0.91。

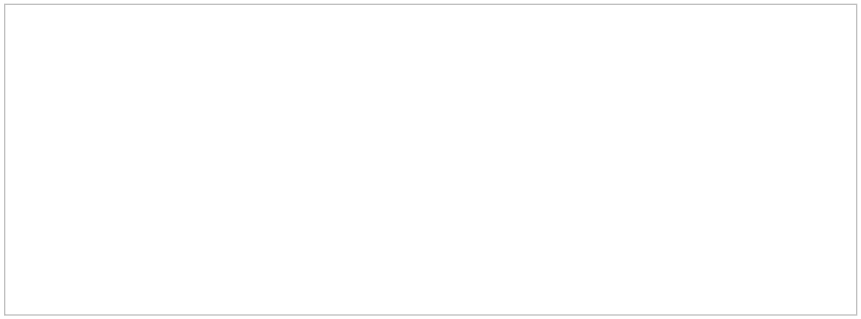
从多头收益来看，GRU在2024年期间的年化收益率为13.43%，夏普比率为0.28；而液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）在同期的年化收益率分别为9.53%、13.50%、10.05%、11.36%，夏普比率分别为0.20、0.30、0.21、0.24。

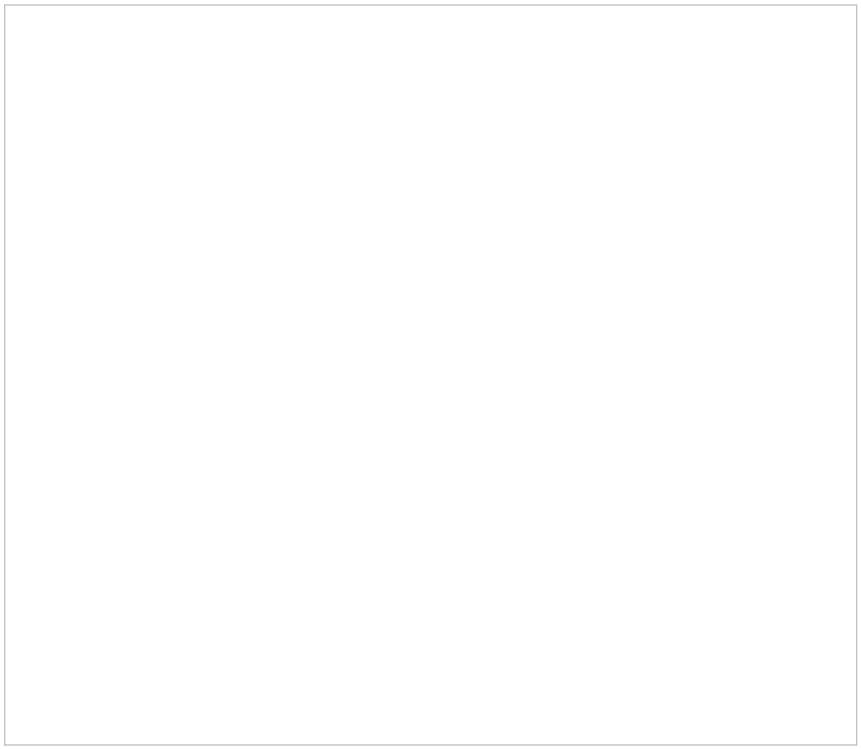
从多空收益来看，GRU在2020~2024年期间的年化收益率为65.57%，夏普比率为5.22；而液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）在同期的年化收益率分别为58.89%、62.41%、60.80%、62.69%，夏普比率分别为5.66、5.26、5.53、5.50。

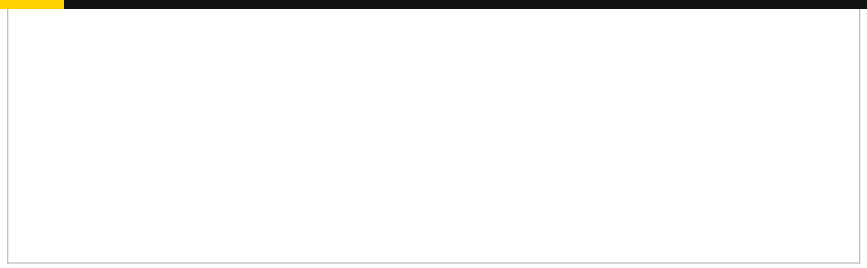
从多空收益来看，GRU在2024年期间的年化收益率为51.50%，夏普比率为2.58；而液态神经网络LTC、NCP（LTC）、CFC、NCP（CFC）在同期的年化收益率分别为39.36%、46.60%、42.64%、41.25%，夏普比率分别为2.48、2.82、2.69、2.23。

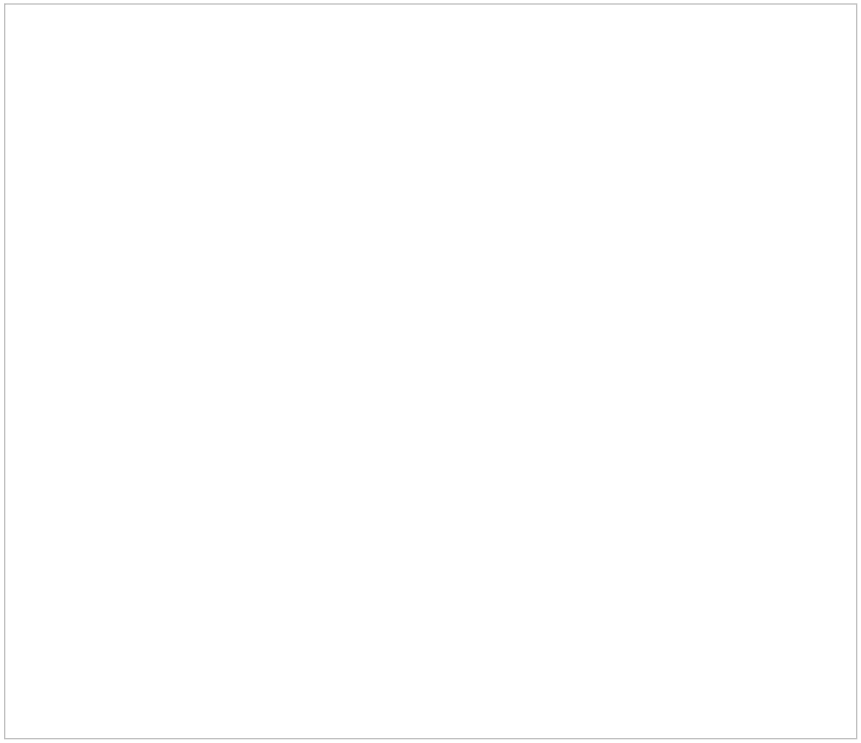


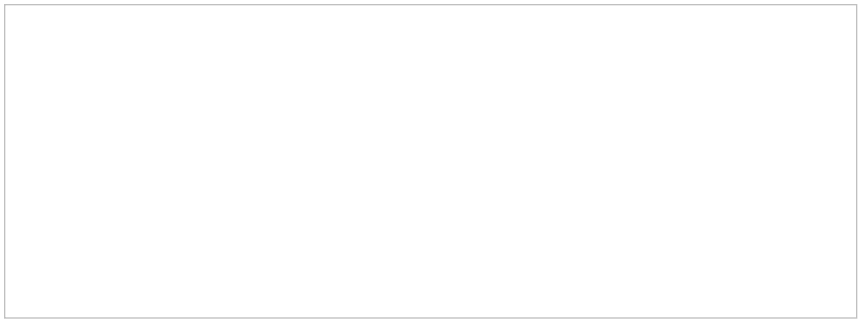


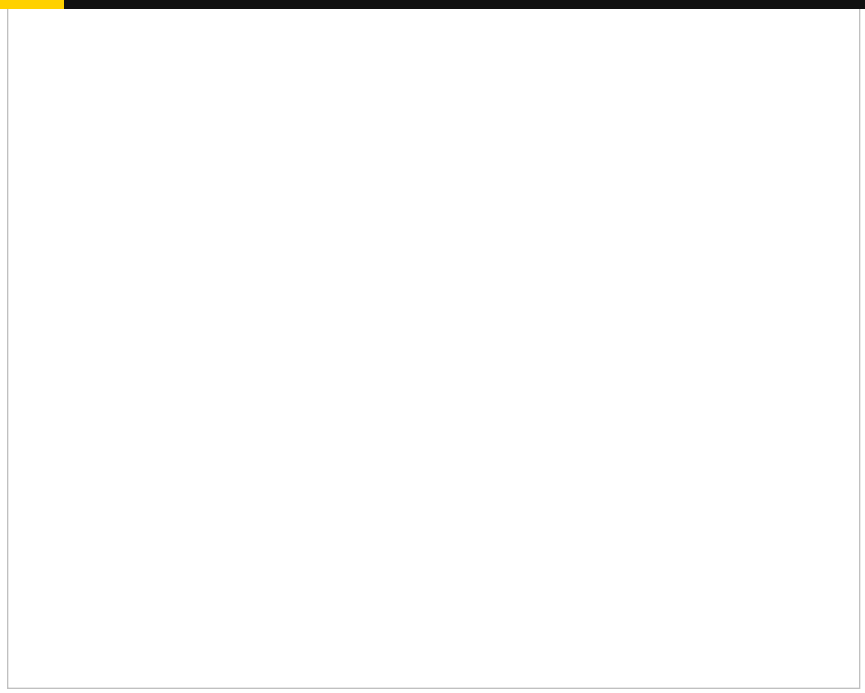


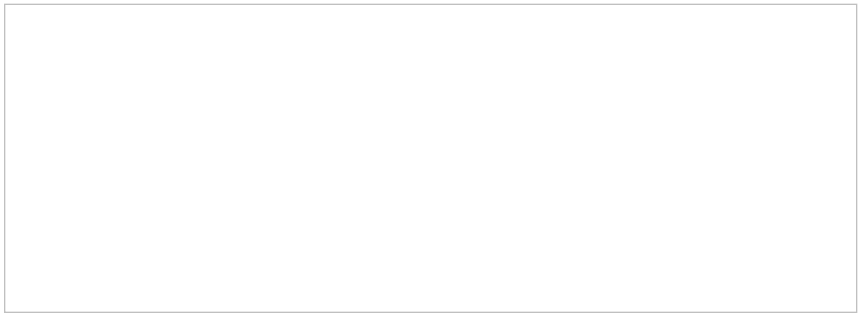


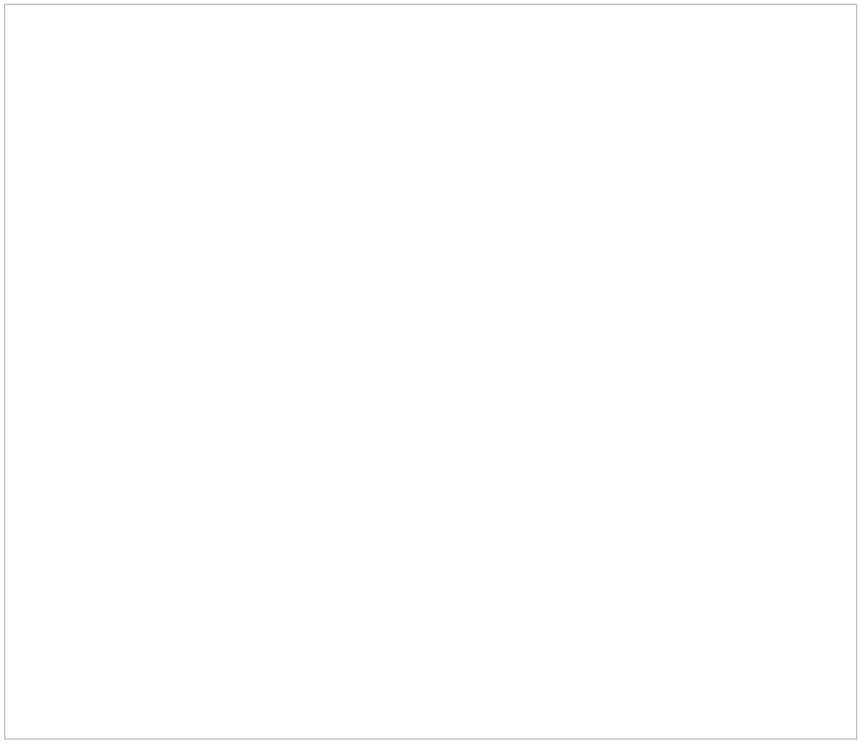












三、总结

常由多个形如h_(t+1)=f(h_t,θ_t)+h_t的残差结构所组成。在常规求解中，需计算出每一个残差结构中最能拟合训练数据的网络参数θ_t。而该论文提出，假设当ResNet网络中的残差结构无限堆叠时，则每一个残差结构的参数θ都可以通过求解同一个常微分方程dh_t/dt =f(h(t),t,θ)来获得。

基于上述工作，来自麻省理工学院的Ramin Hasani等人，创新性地以常微分方程的形式描述循环神经网络的隐藏状态变化，提出了一类被称之为液态神经网络的模型，这些研究成果被发表在《Nature：Machine Intelligence》等国际顶级期刊上。此类模型通过将离散时间步长的循环神经网络“连续化”，使模型具有更好的表征能力。与此同时，稀疏的网络结构带来了更高的计算效率，并且使得模型在异常输入时可以保持优秀的稳健性。这些特性有望使其超过传统的循环神经网络，在量化选股中展现出更优秀的能力。

本研究在保持输入数据、目标函数等非主干网络结构完全一致的情况下，将LTC、NCP（LTC）、CFC、NCP（CFC）四个液态神经网络类模型，与最具代表性的常规循环神经网络GRU进行对比。从结果上来看，主要有以下几个结论：

（1）液态神经网络能够显著降低模型复杂度和显存依赖，以大幅低于传统网络的计算消耗来得到同等结果。具体而言，当同样的数据量在GRU中需要120Gb显存时，在LTC和NCP（LTC）中需约80Gb显存，而在CFC和NCP（CFC）中仅需约6Gb显存，仅为GRU所需显存的5%，这为在有限资源的情况下训练大数据模型提供了可能性；

（2）尽管各个模型的输入数据和目标函数等非主干网络结构一致，但由于主干网络本身所带来的差异使得最终因子呈现出一定的差异化，因子的相关系数在0.69~0.82之间，说明不同的模型能够在相同的数据中学习到不一样的价量特征；

（3）通过分年度的表现统计与对比，上述观点得到了进一步验证，且使用NCP网络结构通常能取得更好的性能。 返回搜狐，查看更多

平台声明：该文观点仅代表作者本人，搜狐号系信息发布平台，搜狐仅提供信息存储空间服务。

阅读 (399)

内容举报

大家都在看

撤销学位不到一天，贾浅浅再迎两大噩耗，父亲贾平凹的…

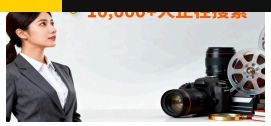

海参不适合哪些人群吃
广告

1988年，29岁的倪萍和冯巩的合影，那时倪萍还未出名，…

一辈子演了两部三级片，至今仍是“亚洲第一美胸”，其中…

九年前“硬杠”王健林，如今被查落马，他在镜头前为民争…

大快人心！人民日报发文，怒斥内娱糊弄观众，《功夫女足…


写真照片
广告

这是一张40年前、令人无限感慨的照片！很多人泪流满面…

阳光跟帖

碎冯小刚体面，养女长相只…

可以@搜狐小编和作者啦
点击登录 @ 搜狐小编 发布