基于风格因子的非线性分域训练研究—机器学习系列九

来源：微信公众号（兴证金工团队）· 机器学习系列九 · 由 URL 转制 PDF 供复现流水线使用

投资要点

- 兴证金工团队自2020年起便积极探索机器学习在量化领域的应用，以树模型为代表的宽基增强策略（沪深300指增等）表现优秀。目前，相关研究主要聚焦于两大方向：一是对现有成熟模型进行持续优化，二是推进新兴模型的实战化验证。**本文以集成树模型为基础框架，在既有对抗训练模型之上，进一步引入分域训练思想，旨在提升模型的综合表现。**
- **基于风格因子的基础面板树分域：与传统以收益率预测为目标的决策树不同，面板树模型以最大化节点组合夏普比率为目标，在构建分组时实现风险对冲。**本研究以风格因子作为特征，通过滚动训练方式动态对样本内外的股票进行分域。结果表明，该方法所得组合在滚动样本外具备较高的夏普比率，且分域结果与传统股票分组方式存在显著差异。
- **面板树与分域训练：**在分域结果基础上，我们引入XGB对抗训练模型构建收益率预测模型。具体通过全域特征标准化、域内标签标准化及分域训练合并三个步骤，对传统预测模型进行改进，构建分域训练下的XGB因子。该分域训练因子在全市场周度测试中Rank IC均值约为0.122，在各股票池内均较基准模型有明显提升。
- **从全集到局部集的优化分域模型改造：分域训练的核心在于依据特定准则筛选出代表性强、同质性高的股票簇作为训练样本，无需全样本参与。**通过对面板树算法进行改进，我们筛选出更具代表性的样本子集作为分域依据，进而构建收益率预测模型。改进后因子在全市场周度测试中Rank IC均值提升至约0.123，且风格相关性进一步降低。
- **复合因子增强测试：**单因子测试表明，**分域训练的因子具备风格相关性降低、股票池内有效性提升的特点。**从沪深300、中证500和中证1000指数增强测试上看，局部优化方案明显提升策略表现，2015年以来增强策略年化超额收益率分别约为12.8%、17.5%和24.1%，超额最大回撤明显收窄，近年来效果尤为显著。

表1、局部优化分域训练因子指数增强超额统计

	年化超额收益	跟踪误差	收益风险比	最大回撤	月胜率	周胜率
沪深 300	12.8%	6.0%	2.14	5.6%	75%	63%
中证 500	17.5%	6.5%	2.71	6.8%	78%	64%
中证 1000	24.1%	6.0%	4.02	6.2%	82%	68%

数据来源：wind，聚源，兴业证券经济与金融研究院整理

注：测试时间窗口为 2015 年初至 2025 年 10 月底

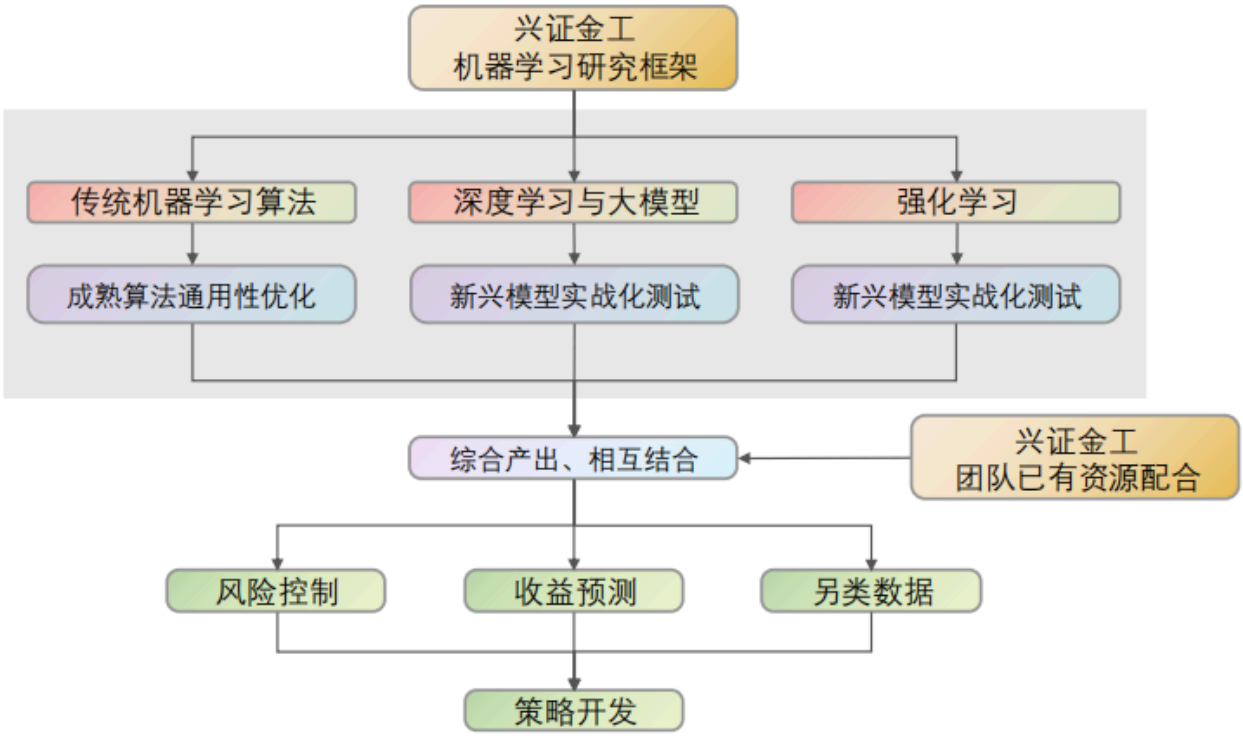
风险提示：模型结果基于历史数据的测算，在市场环境转变时模型存在失效的风险

1、引言

近年来，凭借卓越的数据建模能力，机器学习与深度学习模型在量化金融领域的地位日益重要，相关研究成果不断涌现。**当前，学术界在该领域的研究可大致划分为两个主要方向：成熟算法的优化与新兴算法的探索。**一方面，以无监督学习分类模型、树模型及卷积神经网络为代表的经典机器学习算法已在各类量化投资细分领域积累了丰富的研究基础，近期的创新性工作主要集中于算法性能与有效性上的改进与应用拓展。另一方面，以循环神经网络、大模型及强化学习为代表的新兴算法则侧重于算法层面的创新性研究，众多新兴研究在深度学习框架基础上，结合股票市场特性进行模型架构或训练方法的创新。

兴证金工团队自2020年起便积极探索机器学习在量化领域的应用，并针对传统算法进行了大量的实证测试。时至今日，**我们将机器学习的研究同样划分为两个主要方向：对现有成熟模型的优化以及新兴模型的实战化验证。**在成熟模型优化方面，我们着重于提升改进方法的通用性和有效性，期望所提出的方法论能够适用于多种算法框架，能够让投资者在现有模型上进行低成本改进。而在新兴模型验证方面，我们强调结合团队既有研究积累，并从实际应用的角度出发，考察前沿技术模型在A股市场的有效性。**本文中，我们将以集成树模型作为基础，在此前报告（详见报告《基于树模型的分组优化与风格约束改进—机器学习系列七》）的基础上，尝试将分域训练的思想加入模型训练中，以期望进一步提升模型的表现。**

图1、兴证金工团队机器学习研究框架



数据来源：兴业证券经济与金融研究院整理

在股票收益率预测中，分域训练是提升模型精准度与稳健性的关键策略。传统的全样本收益率预测模型通常忽视了一个事实：A股市场存在显著的风格轮动与结构性差异。例如，科技成长股与金融蓝筹股不仅驱动逻辑不同，其波动特性、对各类因子的敏感性也迥异。若使用同一模型拟合全市场，类似于试图用一套规则解释所有现象，模型参数实则为各子域特征的“模糊折中”，其预测往往停留在市场平均水准，难以捕捉细分机会。**不同于全域建模，分域建模的核心思想是“分类处理，精准建模”。**它将全市场股票依据行业属性、市值规模、风格标签（如成长/价值）或波动特征划分为相对同质的子域，再为每个子域独立构建预测模型。这种做法的优势在于允许模型更聚焦于特定域内最有效的预测因子。同时，分域建模能更准确地刻画不同域特有的非线性关系与波动模式。最后，分域建模或有效隔离风险，防止某一域的异常波动或结构性变化通过统一模型参数污染其他域的预测。

本文中，我们将突破传统的线性分域方法，以风格因子作为基础，通过引入面板树模型，并进行适度改造以实现对训练集的非线性分域处理，并进一步基于分域后的样本差异进行精准建模，最终期望其能够提升基准模型的表现。

本文结构安排如下：

- **基于风格因子的非线性股票分域：**我们首先介绍基础的面板树模型，包含面板树的初衷以及其和分域建模的相关性。进一步，我们基于风格因子套用面板树进行基础的动态股票分域；
- **基于分域的收益率预测模型：**基于基础分域后的结果，我们采用滚动训练的形式进行基于分域样本的收益率预测模型搭建。具体来说，我们通过构建多头和空头数据集，并针对特征和Label采用不同的标准化方式，最后结合分域预测部分合并得到因子值；

- **非线性股票分域模型改造与分域训练：**针对上文基础分域模型遇到的问题，我们尝试提出改造方式，通过引入代表域的概念对面板树和分域训练框架进行改造，并进一步测试改造后因子值的表现；
- **分域训练模型增强测试：**最后，我们在相对严格的约束条件下进行针对沪深300、中证500和中证1000指数增强的测试。

2、基于风格因子的非线性股票分域模型

本节中，我们将首先引入面板树的概念，从模型初衷、原理介绍到适应性改造，逐步将面板树与风格因子结合，以共同实现针对样本数据的非线性分域。

2.1 面板树：以全局夏普比率作为优化目标的树结构

面板树模型（Panel Tree，可简称P-Tree）是一种用于分析面板数据的机器学习方法，它结合了决策树的非参数特性与面板数据的结构特点。P-Tree相对完整的框架始于2021年发表于SSRN的论文《Asset Pricing with Panel Tree under Global Split Criteria》。P-Tree的核心创新在于提出了**全局分裂准则：即分裂不再只考虑单个节点，而是以提升整个横截面资产组合的夏普比率等经济指标为目标。**这使得模型生长具有明确的经济学指引，直接服务于构建更好的投资组合或定价因子。在这篇文章中，作者基于美国市场数据，通过P-Tree识别出驱动美股截面收益的关键特征交互（如长期反转、交易量波动与规模），在定价个股和投资组合方面，优于大部分已知的显性和隐性因子模型。在2025年金融学顶刊《Journal of Financial Economics》上发布的论文《Growing the Efficient Frontier on Panel Trees》，作者在资产定价实证中验证该模型，并进一步深化实证展示有效前沿的外推。

2.2 基于风格因子的基础面板树构建

在本节中，我们将直接介绍以风格因子搭建的非全域面板树，并以此展开对于面板树模型的介绍。具体来说，面板数的训练和预测大致框架与传统机器学习模型基本一致。具体如下：

- **数据准备和预处理**

我们同样采用年度重新训练的形式进行滚动训练。在每次训练时，我们选用2009年至训练集时间末端的月频数据作为训练集。具体数据维度包含：每月最后一个交易日所有股票的风格因子值数据，以及对应的未来一期股票收益率作为标签；每期每只股票（记为单个样本）以10个风格因子Beta、Book-to-Price、Earnings Yield、Growth、Leverage、Liquidity、Momentum、Nonlinear Size、Residual Volatility和Size作为特征数据，记为本次训练的完整面板数据。

在完整面板数据的基础上，我们对预期收益率和特征数据进行常规清洗与预处理：对预期收益率数据，将个股名义月度收益减去固定的月度无风险利率，之后进行1%—99%分位截尾，以抑制极端观测的影响；对特征数据，以月份作为横截面，对因子取值进行线性缩放，将不同量纲的因子映射到可比的[0,1]区间，缺失因子值统一使用中位数进行填补。

- **超参数确定**

处理好数据后，我们进一步基于训练集进行超参数确定。对于面板树而言，其本身涉及的超参数较少，核心超参数包含树的最大深度以及最大分裂轮数（类比于叶子个数）。我们将其设置为5层和30轮次。其他参数设定如下。

表 2、面板树核心超参数设定

超参数	含义	推荐范围
max_depth	树的最大深度，控制分裂层数与结构复杂度	一般 3–6 层；本文设置为 5 层；
min_leaf_size	每个叶节点最小样本数	一般≥20；较多的最小样本数可以保证叶子收益稳定；本文设置为 100；
num_cutpoints	每个特征在[0,1]区间上尝试的候选切分点数量	一般 3–10；越大搜索越精细，但训练速度越慢，本文设置为 4；
max_iter	最大分裂轮数上限（防止无限生长）	多数情况 10–50 之间足够，本文设置为 30；

数据来源：兴业证券经济与金融研究院整理

- **面板树的生长过程**

Step1：在给定的训练期内，模型首先将所有股票—月份样本视为一个整体根节点，按市值加权得到全集合组合的月度收益，并在叶子空间为1的情况下求解最大$Sharpe^2$组合，记下对应的$Sharpe^2$作为基准。

Step2：随后进入迭代生长过程。每一轮中，从当前所有叶节点中筛选出仍满足深度和样本量约束的节点，围绕可用的特征生成一系列特征—阈值候选切分，对每一个候选切分，按照高于/低于阈值的规则把该节点样本划分为左右两组，分别构造新的市值加权叶子组合收益；在保持其他叶子不变的前提下，将新旧叶子收益拼成新的叶子收益矩阵，重新在这一矩阵上做一次均值—方差优化。由于预期协方差矩阵和预期收益率均采用历史数据进行计算，因此可以直接通过每个叶子的组合收益率Rk，推导得出在指定组合收益率矩阵下的最优权重解，具体公式如下。得到更新后的最优$Sharpe^2$，并以$Sharpe^2$提升幅度来评价该切分的好坏。

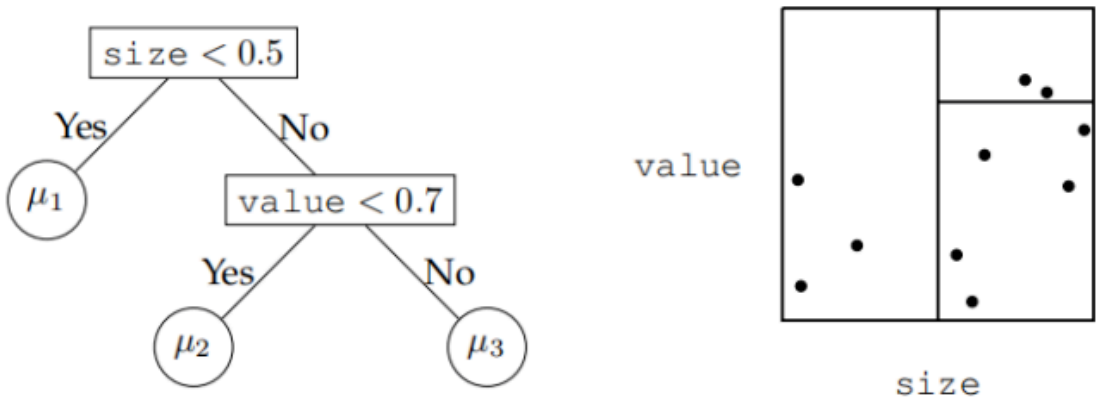
表3、面板树内部特征计算公式

权重指标	公式	符号说明
叶内股票权重	$\omega_{i,t\|n}=\frac{\mathrm{MC}_{i,t}}{\sum_{j\in\mathcal{S}_{n,t}}\mathrm{MC}_{j,t}}$	$\mathrm{MC}_{i,t}$：股票i在t月流通市值；$\mathcal{S}_{n,t}$：t月落入叶子n的股票集合；$\omega_{i,t\|n}$：股票i在叶子n内的权重占比
叶子权重（单棵树）	$\tilde{\mathrm{w}}=(\mathrm{Cov}(\mathrm{R})+\gamma\mathrm{I})^{-1}\mathbb{E}(\mathrm{R})$	$R=(R_1,\ldots,R_K)^{\top}$：训练窗口内叶子组合收益向量；$\mathrm{Cov}(\mathrm{R})$、$\mathbb{E}(\mathrm{R})$：叶子收益的协方差与均值估计；$\gamma\mathrm{I}$：对角收缩，避免过拟合；w：叶子层面组合权重
股票权重（单棵树）	$W_{i,t}^{\mathrm{single}}=w_{n(i,t)}\cdot\omega_{i,t\|n(i,t)}$	$n(i,t)$：股票i在t月被分配到的叶子编号；$w_{n(i,t)}$：该叶子的叶子权重；$\omega_{i,t\|n(i,t)}$：叶内权重；$W_{i,t}^{\mathrm{single}}$：单树最终持仓权重

数据来源：兴业证券经济与金融研究院整理

Step3：每轮中，通过遍历测试，得到多组切分结果以及对应的Sharpe^{2}结果。模型选择Sharpe^{2}提升最大的那一个切分写入树结构，用原叶节点替换为左右子节点，同时更新当前的最优Sharpe^2；当所有叶节点都不再存在能带来显著Sharpe^2 改善的切分，或进一步分裂会导致叶子样本过少、树深度过大时，生长过程自动停止，得到一棵结构适中、以Sharpe^{2}最大化为目标训练出来的面板树结构。

图2、面板树分裂示意图

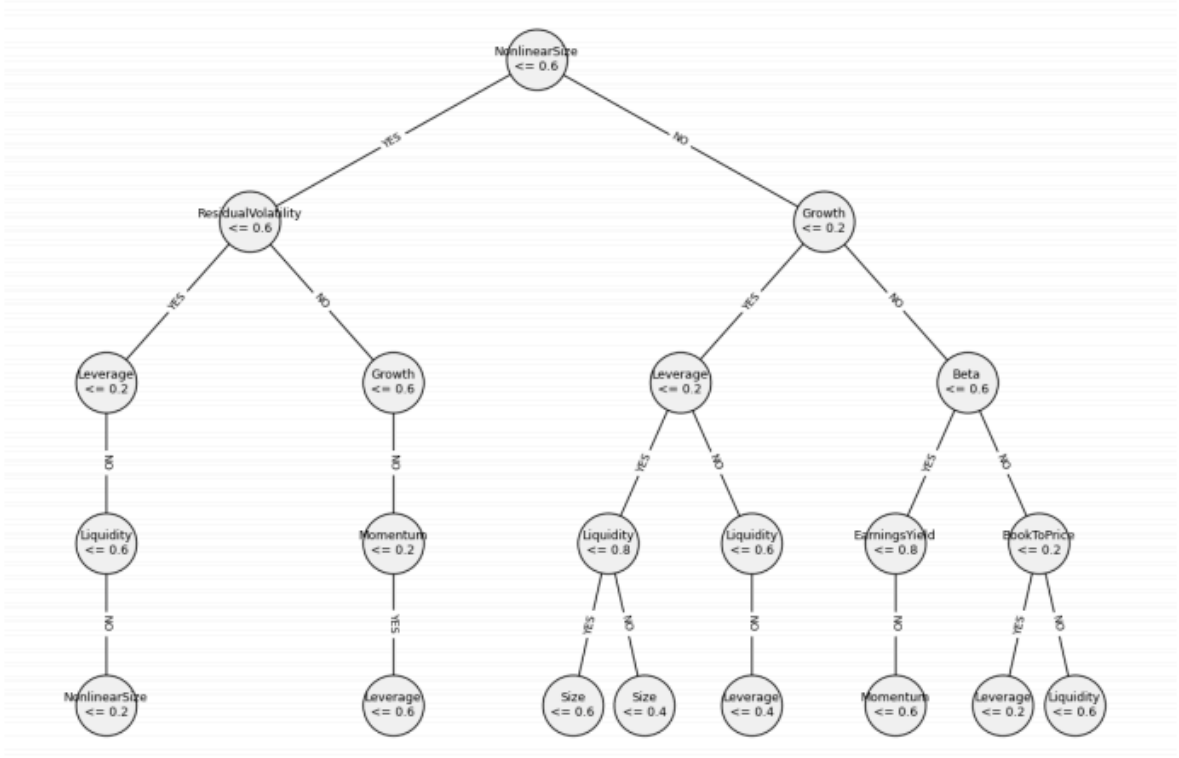


数据来源：兴业证券经济与金融研究院整理

最终，我们的数据起始日期为2009年。为了能够以足够的数据进行训练和预测，我们以2014年底作为首次训练的训练集截止日期，首次预测数据集为2015年全年，数据频度为周度。因此，我们最终的面板树样本外可得时间范围为2015年至2025年。在每年训练中，我们能够得到共计三类数据：训练得到的叶子节点以及对应权重、样本内外每期每只股票所属叶子标签以及个股权重数据。

我们以某一年数据构建的面板树结构作为样例展示。从分裂的结果上看，各个分裂点和传统认知存在一定的共通性：如非线性市值、特质性波动性和流动性等在A股市场相对显著的特征出现的次数较多，抑或者出现的层级较高。但整体由于其非线性的特质，我们难以直接通过图中结构看出分裂规律。

图3、风格因子面板树结构示意图



数据来源：兴业证券经济与金融研究院整理

综上，我们可以看出与传统的决策树不同，面板树存在以下两点核心差异：

1、 **从“局部统计”到“全局经济”的分裂逻辑：**传统决策树的分裂是“短视”的。例如在回归问题中，它会选择一个特征和切分点，使得分裂后两个子节点的方差之和最小。这个过程只关心当前节点的拟合改善。面板树的分裂则相对具备“远见”的。以资产定价为例，它的每一次分裂都是在解决如何将所有股票分成两个群体，才能使由这两个群体收益率之差构成的因子投资组合的夏普比率最高？这个目标函数贯穿整个树的生长过程，确保了最终模型直接服务于一个核心经济目标。

2、 **从“忽略结构”到“嵌入结构”的数据处理：**传统决策树无视面板数据中个体的异质性和时间序列相关性，通常将不同时期的同一公司视为独立样本，无法有效捕捉个体效应与特征变量随时间的复杂交互。面板树在模型设计上内嵌了面板结构：它假设最终的树结构是时不变的，但允许叶节点的预测值随时间变化。这既保证了模型的稳定性，又容纳了时间维度信息，能有效识别“在何种宏观状态下，哪些公司特征会变得重要”。

3、 **叶子结点本质为内部同质、相互异质的风格代表：**以最大化夏普比率为目标，意味着模型在构造分组时会自动寻求对风险的对冲。例如，它可能将“高价值但高波动”的股票与“低价值但低波动”的股票分离，使最终的多空组合剥离了单纯的风格暴露。**从面板树的角度上看，市场中存在着基于Barra风格因子，但非线性组合的因子溢价。**模型通过分裂，将每期每只股票根据其特征区分为**内部同质、相互异质**的簇，并对这些簇构建多空组合。若这一多空组合能够剥离市场上绝大多数风险，则说明这些股票分组之间的风格存在差异化，具备一定的代表性。

表4、决策树和 Panel Tree 的差异

维度	传统决策树（分类 / 回归）	Panel Tree
主要任务	预测标签或数值（分类、回归）	构建高 Sharpe 的资产组合
数据假设	**数据点独立同分布，不考虑个体或时间关联**	**处理面板数据，明确建模个体差异与时间动态。**
优化目标	提高预测准确率、降低均方误差	在保证预测力的同时，识别具有经济意义的结构和交互作用
分裂评估的粒度	**局部准则：分裂以最大化当前节点内数据的“纯度”或最小化均方误差为目标。**	**全局准则：分裂以提升整个面板数据样本构建的资产组合的夏普比率为导向。**
常用分裂准则	Gini 指数、熵、MSE 等	在新叶子收益矩阵上重新做一次均值–方差优化，比较最优组合夏普比率的变化
输出对象	每个样本对应一个预测标签或预测值	输出一个稳定的分组结构（树），该结构能生成可交易的资产组合或定价因子。核心应用于资产定价、经济分析。
经济含义	**强调特征对结果变量的预测能力**	**强调特征在风格控制之后对组合收益/风险结构的影响**
截面划分的视角	关注样本在标签空间的纯度	关注样本在“风格因子条件下”的收益差异与 Sharpe 提升

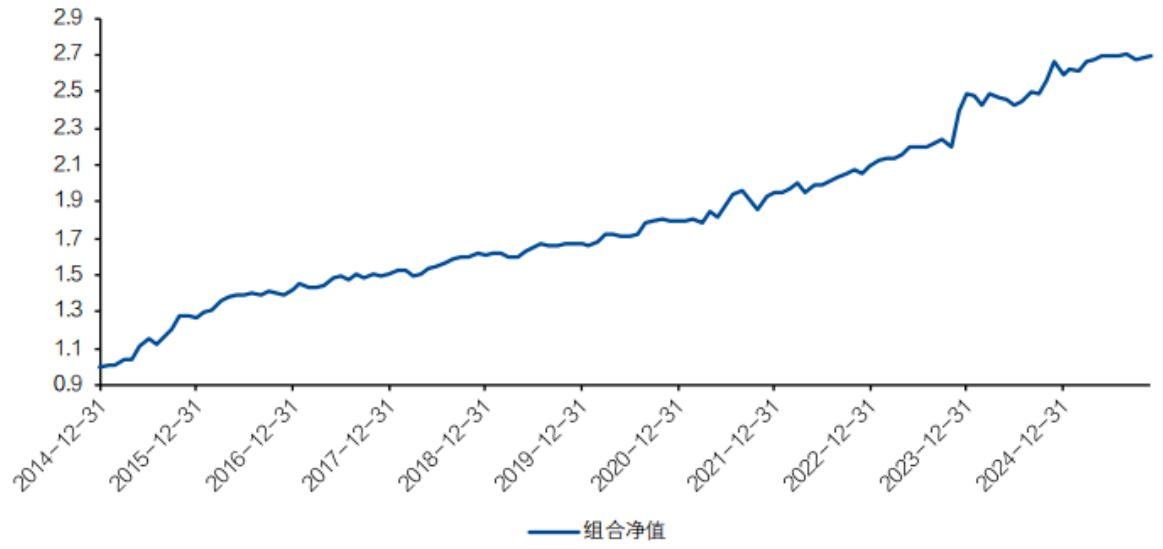
数据来源：兴业证券经济与金融研究院整理

2.3 基础面板树有效性检验与分组结果特征统计

在上文中，我们已经基于Barra风格因子和基础面板树设置了滚动训练。具体来说，我们在每年年底基于延展窗口进行面板树的训练，并使用未来一年的数据进行基于面板树的组合权重预测。因此，我们以2015年以来的测试集组合净值作为衡量标准，以查看面板树构建的组合是否具备较高的组合夏普比率。

从测试结果上看，基于Barra风格因子构建的面板树在测试集上的表现优秀，其整体净值的夏普比率较高，收益风险比全时段内为1.52，且每年度均相对稳定。

图4、面板树测试集组合净值



数据来源：wind，聚源，兴业证券经济与金融研究院整理

表5、面板树测试集组合表现统计

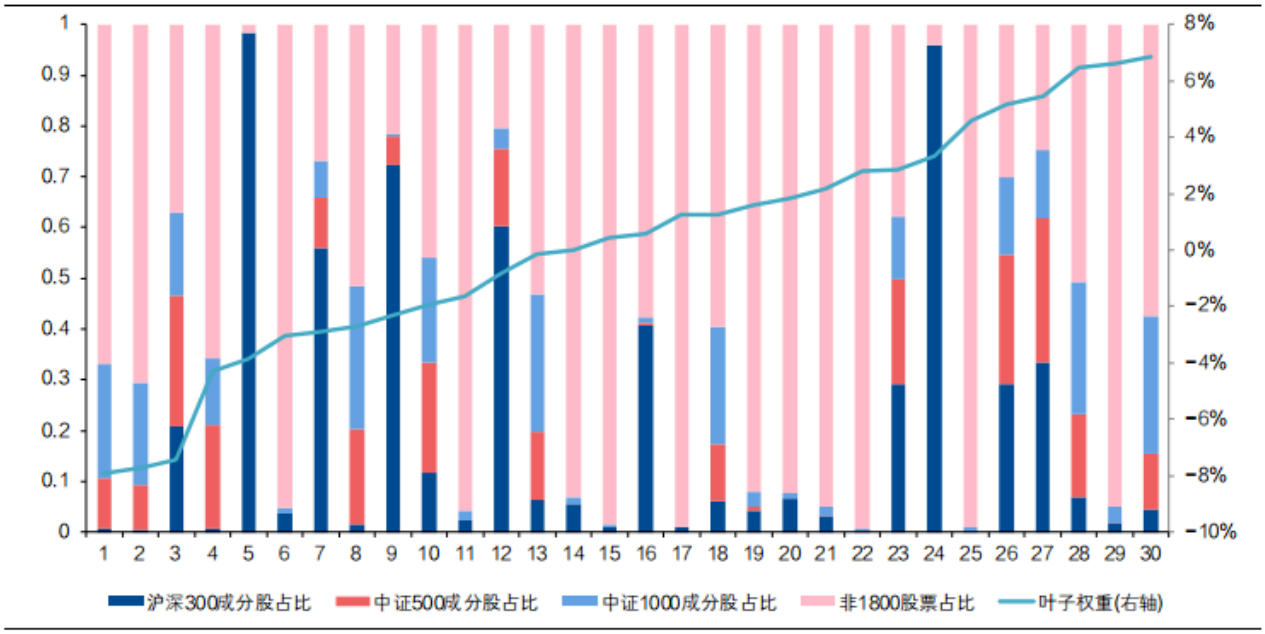
	年化收益率	年化波动率	收益风险比	最大回撤	收益回撤比	月度胜率
2015	27.1%	9.5%	2.87	2.37%	11.43	61.5%
2016	11.9%	4.5%	2.63	1.25%	9.54	69.2%
2017	6.0%	4.5%	1.31	1.25%	4.75	53.8%
2018	7.0%	3.4%	2.05	2.03%	3.44	76.9%
2019	3.7%	2.7%	1.36	1.40%	2.66	53.8%
2020	7.6%	4.0%	1.91	0.82%	9.24	61.5%
2021	8.5%	8.0%	1.06	5.33%	1.60	53.8%
2022	7.4%	4.3%	1.73	2.31%	3.22	61.5%
2023	18.5%	9.1%	2.04	1.95%	9.50	76.9%
2024	4.2%	7.0%	0.60	2.71%	1.56	38.5%
2025	3.8%	2.9%	1.32	1.27%	3.00	53.8%
全时段	9.4%	6.2%	1.52	5.33%	1.76	64.7%

数据来源：wind，聚源，兴业证券经济与金融研究院整理

更进一步，我们尝试针对分组的结果进行统计说明。具体来说，我们以2024年年底的模型作为数据，分析基于面板树分组得到的结果和传统的股票分域结果有何差异。

首先是成分股的分组结果，这也是传统分域训练中最为常用的股票分域方式。我们根据每个叶子内部的样本，统计其属于沪深300、中证500、中证1000以及其余股票的占比，并按照叶子权重从低至高排序进行展示。从图中可以看出，每个叶子每部的成分股占比各不相同，这说明基于面板树分域得到的组并未完全能够由成分股分组替代。此外，沪深300、中证500和中证1000指数成分股占比和叶子权重之间的相关系数约在-6.30%、-7.85%和-9.64%左右，整体相关系数极低。这说明并未出现如权重越大的叶子某类成分股占比越高的情况。这也进一步**说明面板树的分域结果无法被成分股分组替代。**

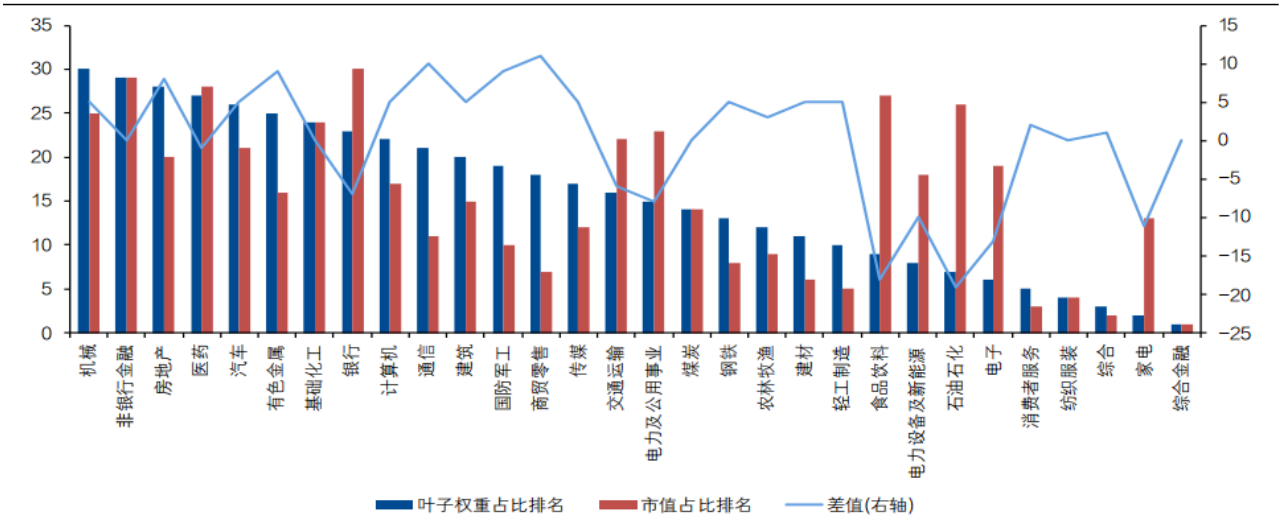
图5、叶子内部成分股占比统计



数据来源：wind，聚源，兴业证券经济与金融研究院整理

我们进一步展示分域后行业分布权重上的差异。具体来说，我们首先基于流通市值，统计各个行业历史至今在全市场范围内的加权占比市值，并改为排序值，用于表征市场上行业占比的整体情况。其中排序值越大说明其整体占比越高。根据叶子权重分配的结果上看，机械、非银行金融、房地产、医药和汽车自历史以来的市值占比较高，而若以流通市值作为权重计算时，这类行业的权重占比较低，**这一定程度上体现出面板树分域和行业分域上的差异。**

图6、叶子分域上的行业权重分布差异

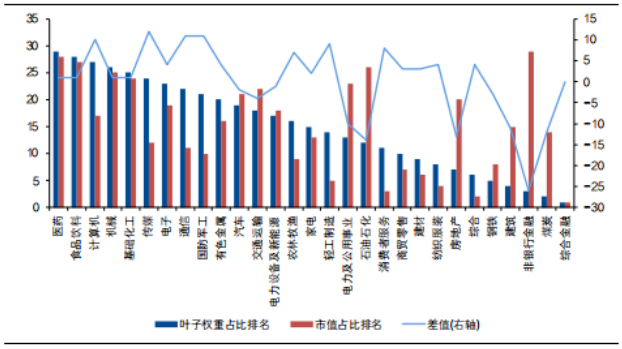


数据来源：wind，聚源，兴业证券经济与金融研究院整理

除此之外，我们也单独拎出权重最大和权重最小的两个叶子域，统计叶子域内部的行业分布，具体如下。首先是左侧权重最大的叶子域，权重排名较高的行业是医药、食品饮料和计算机，这与整体行业

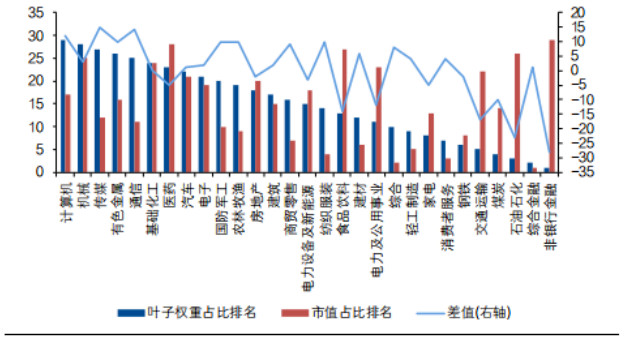
分布以及叶子配权下的行业分布也不尽相同。右侧的最小权重叶子亦是如此，这一定程度上表明了分域的差异性。

图7、叶子内部行业分布与全市场行业分布对比—权重最大叶子



数据来源：wind，聚源，兴业证券经济与金融研究院整理

图8、叶子内部行业分布与全市场行业分布对比—权重最小叶子



数据来源：wind，聚源，兴业证券经济与金融研究院整理

3、结合分域训练的XGB收益率预测模型

在上一章节中，我们基于Barra风格因子，采用滚动训练的形式实现了每年度的训练集分域结果以及预测集的分域结果，且每个分域结果数据包含每期每只股票的所属叶子结点、对应权重以及每个叶子结点的权重。在本节中，我们将尝试基于分域结果，结合之前的XGB训练框架，进行分域训练。

3.1 分域下XGB训练流程

在前序研究的基础上，我们基于分域得到的结果，采用分域训练、合并加权的形式进行训练。首先是数据准备和特征预处理部分。

- **数据准备与特征预处理**

我们选用2009年至训练集时间末端的所有数据作为训练集。具体数据维度包含：每周最后一个交易日所有股票的因子值数据，以及对应的未来收益率作为标签；每期每只股票（记为单个样本）包含近220个特征（因子），其中基于分钟数据构建的因子个数约为70个，其余为基于日度以及更低频数据构建的低频因子，因子风格涵盖价值、成长、质量、情绪、动量反转和另类。除此之外，我们也进一步准备每个样本的Barra十风格因子，用于对抗训练和面板树分域。为了避免泄露数据，我们统一采用分割处理：即完全基于训练集数据确定处理方式，再进一步套用至测试集。具体步骤包括：（1）样本和特征筛选：以训练集为对象，我们首先删除特征覆盖度不足85%的样本，再进一步在剩余样本中统计特征覆盖度，剔除覆盖度不足85%的特征；（2）变量预处理：对于解释变量X，我们在时间截面上进行稳健的

ZScore标准化（稳健ZScore标准化方法使用中位数和中位数绝对偏差（MAD）来替代均值和标准差）；**在本步骤中，我们将特征放在全市场范围内进行处理，但是对于Label，即预测对象我们将在下文中进行操作。**

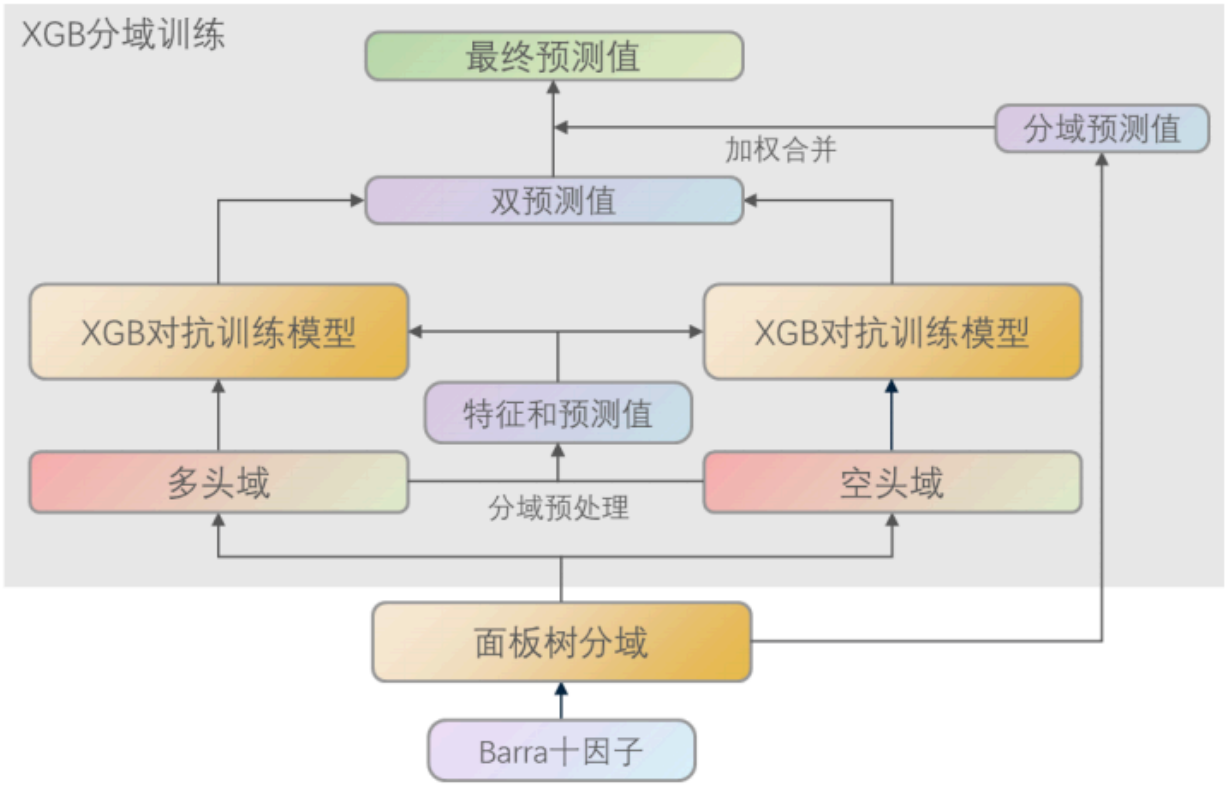
- **对抗训练设定**

为了规避A风格暴露的影响，我们沿用前序文章（详见报告《基于树模型的分组优化与风格约束改进—机器学习系列七》）中对于风格约束的改进方式，以控制市值、流动性和特质性波动率作为训练方式进行对抗训练。

- **分域训练设定**

在准备好数据之后，我们进一步进行XGB框架下的股票分域训练。首先，在每年年末，我们基于2009年至训练结束的所有股票以及对应Barra风格特征，以月度作为数据频率，进行面板树的训练，得到在全训练样本内的叶子分域结果，并标记出每个叶子的权重，以及针对每个样本的叶子标签。接下来，我们按照以下步骤进行本期的分域训练。具体来说，分域训练相对于传统训练模型，在特征、Label和预测融合三维度均存在一定差异。我们通过全域特征标准化、域内Label标准化和分域训练合并，这三个步骤得到分域训练下的XGB因子。

图9、XGB 分域训练框架



数据来源：兴业证券经济与金融研究院整理

在确定好模型训练步骤后，我们以年度为单位，每个年末根据2009年至今的数据作为训练集，通过上述步骤进行训练得到模型，并以未来一年内的数据作为预测集预测得到Alpha因子值，并以年度为单位进行重新训练。在本章的预测对象上，我们基于未来10个交易日收益率进行训练，记为domainXGB。

3.2 基准分域训练模型表现统计

在单因子的回测设定上，我们以周度调仓的形式进行回测，且股票池剔除当时不在市、特殊处理以及涨跌停的股票。测试时间范围为2015年初至2025年10月底。此外，在针对沪深300和中证500指数的分位数组合测试中，我们设置五分组测试；在中证1000和全市场测试中，我们的分组设置为10分组。后续如无特殊说明，因子回测均采用上述测试方法。

我们首先展示基础分域因子和基准模型（即前序章节的XGB模型）的回测结果：首先是Rank IC测试结果：从测试结果上看，基础分域因子的表现相对优秀，其全市场周度测试Rank IC均值约为0.122，IC IR约为1.01，表现出极强的稳定性，但全市场范围测试相对基准模型并未明显提升；在不同股票池内的测试中，分域训练因子的表现更加优秀，且相对基准模型明显提升：以沪深300内的测试结果为例，其因子Rank IC均值为0.076，相对基准模型的0.067有明显提升，IC IR也相对提升；此外，分域训练因子在中证500和中证的回测表现中同样存在提升，因子Rank IC均值稳定在0.095至0.11左右，相对基准均有一定提升。

表6、分域训练模型 Rank IC 测试结果

股票池	因子名称	平均值	标准差	IC_IR
全市场	domainXGB	0.122	0.121	1.006
	stylePenXGB	0.124	0.120	1.040
沪深 300	domainXGB	0.076	0.162	0.467
	stylePenXGB	0.067	0.151	0.440
中证 500	domainXGB	0.095	0.137	0.691
	stylePenXGB	0.091	0.122	0.744
中证 1000	domainXGB	0.113	0.128	0.879
	stylePenXGB	0.109	0.122	0.891

数据来源：wind，聚源，兴业证券经济与金融研究院整理

进一步，我们展示分位数组合的测试结果：从测试结果上看，在各个股票池的测试范围内，分域训练的因子domainXGB相对基准因子均有明显提升，尤其是在多头组上。以全市场范围为例，domainXGB因子的多头年化超额提升约5%，多空夏普比率从之前的6.96提升至7.08；此外，domainXGB因子在沪深300、中证500和中证1000指数成分股内因子的多头年化超额提升约3-7%，多空夏普比率提升至约0.1-0.3，呈现出明显稳定的全范围内提升。

图10、分域训练模型分位数组合测试结果

全市场

stylePenXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	47.74%	32.15%	1.48	79.77%	37.89%	35.26%
1	33.67%	28.69%	1.17	130.83%	35.18%	21.57%
2	27.67%	26.87%	1.03	145.57%	37.29%	15.68%
3	23.46%	25.58%	0.92	152.07%	35.35%	11.58%
4	17.81%	24.81%	0.72	155.53%	38.44%	6.23%
5	14.17%	24.42%	0.58	156.50%	46.95%	2.82%
6	8.88%	24.18%	0.35	155.49%	57.46%	-2.38%
7	1.90%	24.18%	0.08	151.04%	65.45%	-8.35%
8	-7.58%	25.45%	-0.30	140.81%	86.19%	-16.69%
Bottom	-37.99%	29.45%	-1.29	96.54%	99.72%	-43.76%
市场	10.56%	25.84%	0.41		50.31%	
L-S	133.87%	19.23%	6.96		21.40%	

domainXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	53.51%	31.51%	1.70	91.46%	37.38%	40.28%
1	39.24%	29.24%	1.34	142.28%	35.60%	26.75%
2	30.03%	27.57%	1.09	155.02%	35.61%	18.01%
3	23.76%	26.63%	0.89	160.14%	35.83%	12.12%
4	16.92%	25.33%	0.67	162.18%	39.00%	5.51%
5	11.77%	24.61%	0.48	161.95%	46.04%	0.73%
6	6.05%	24.18%	0.25	159.71%	56.71%	-4.58%
7	-0.32%	24.15%	-0.01	154.84%	72.58%	-10.38%
8	-11.12%	25.02%	-0.44	145.01%	90.66%	-20.03%
Bottom	-37.26%	28.22%	-1.32	105.13%	99.63%	-43.31%
市场	10.56%	25.84%	0.41		50.31%	
L-S	140.23%	19.81%	7.08		16.70%	

沪深300

stylePenXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	14.59%	21.15%	0.69	65.50%	28.45%	9.03%
1	11.92%	20.55%	0.58	115.98%	33.10%	6.62%
2	9.42%	21.07%	0.45	125.13%	39.05%	4.34%
3	0.36%	21.83%	0.03	119.16%	64.87%	-3.99%
Bottom	-11.39%	24.13%	-0.47	72.30%	89.34%	-15.16%
市场	4.82%	20.83%	0.23		45.90%	
L-S	26.88%	15.38%	1.75		19.70%	

domainXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	17.97%	20.99%	0.86	70.78%	34.18%	12.21%
1	13.05%	20.69%	0.63	119.33%	37.13%	7.71%
2	6.65%	20.99%	0.32	128.21%	39.04%	1.70%
3	-1.02%	22.04%	-0.05	123.16%	64.33%	-5.47%
Bottom	-11.20%	24.18%	-0.46	80.77%	88.04%	-14.98%
市场	4.82%	20.83%	0.23		45.90%	
L-S	30.27%	15.64%	1.93		27.35%	

中证500

stylePenXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	23.30%	25.79%	0.90	68.81%	33.41%	15.20%
1	15.74%	24.70%	0.64	116.05%	38.31%	7.97%
2	10.15%	24.37%	0.46	125.37%	44.26%	3.64%
3	3.17%	23.51%	0.13	119.03%	61.65%	-4.03%
Bottom	-14.23%	25.97%	-0.55	73.44%	93.08%	-19.98%
市场	7.21%	24.25%	0.30		51.66%	
L-S	42.31%	13.01%	3.25		16.76%	

domainXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	27.46%	25.91%	1.06	76.61%	33.78%	19.00%
1	17.28%	25.01%	0.69	123.88%	33.48%	9.48%
2	11.11%	24.21%	0.46	131.17%	45.82%	3.56%
3	0.81%	24.13%	0.03	124.75%	68.31%	-6.12%
Bottom	-16.35%	25.83%	-0.63	83.02%	93.97%	-21.96%
市场	7.21%	24.25%	0.30		51.66%	
L-S	50.42%	15.23%	3.31		18.55%	

中证1000

stylePenXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	36.36%	31.49%	1.15	85.04%	42.05%	26.96%
1	28.25%	29.04%	0.97	136.28%	39.40%	18.80%
2	25.15%	28.10%	0.89	150.06%	40.78%	15.76%
3	20.92%	27.44%	0.76	156.45%	40.39%	11.66%
4	14.57%	26.92%	0.54	158.57%	46.49%	5.66%
5	12.60%	26.09%	0.48	159.34%	59.96%	3.60%
6	7.41%	26.28%	0.28	157.69%	62.62%	-1.15%
7	-0.47%	25.72%	-0.02	152.67%	74.06%	-8.61%
8	-8.36%	26.15%	-0.34	141.90%	88.42%	-16.20%
Bottom	-35.04%	29.71%	-1.18	95.61%	99.59%	-39.96%
市场	8.34%	26.90%	0.31		56.47%	
L-S	106.15%	18.27%	5.81		16.54%	

domainXGB	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	44.12%	31.46%	1.40	96.09%	39.86%	34.03%
1	33.11%	29.50%	1.12	145.86%	43.37%	23.47%
2	26.40%	28.79%	0.92	157.26%	39.86%	17.08%
3	22.77%	27.91%	0.82	161.85%	39.58%	13.51%
4	15.45%	27.12%	0.57	163.91%	49.87%	6.52%
5	9.91%	26.86%	0.37	162.78%	51.37%	1.34%
6	4.36%	25.94%	0.17	161.31%	63.17%	-4.02%
7	-3.01%	25.97%	-0.12	156.65%	80.39%	-10.88%
8	-12.11%	26.18%	-0.46	145.39%	92.42%	-19.36%
Bottom	-35.93%	28.52%	-1.26	103.95%	99.55%	-41.06%
市场	8.34%	26.90%	0.31		56.47%	
L-S	120.73%	20.17%	5.99		16.73%	

数据来源：wind，聚源，兴业证券经济与金融研究院整理

4、分域模型改造—从全集到局部集优化

在上一章节中，我们已经基于基础的面板树分域结果，通过全域特征标准化、域内Label标准化和分域训练合并三个步骤得到了分域训练下的XGB因子，并取得了一定的提升。在本节中，我们将进一步改进面板树，通过构建代表域的形式，提升分域训练的差异化，并最后达到对模型效果的提升。

4.1 面板树改进—基于代表域的面板树

本节中，我们将尝试对经典面板树模型进行适配性改进，以契合特定的分域训练目标。在基础面板树框架中，优化问题的定义域为全市场股票集合，其目标是学习能够使基于全部样本构建的多空组合夏普比率最大化的全局性规则。

然而，分域训练的应用场景并非要求全市场股票参与。具体而言，分域训练的核心在于：**依据特定的表征准则筛选出具有高度代表性和同质性的股票簇作为训练样本；模型的学习目标并非在全市场中寻找普适规律，而是在此限定域内，构建对于该特定样本子集预测最优的模型。**这一过程旨在精准剥离该簇股票所共有的风格特质，或萃取其内部特有的收益生成规律，但并未要求全市场参与。

因此，在面板树模型中，**若将优化域由全市场股票全集改为局部股票子集后，模型能够输出更高的夏普比率，这一结果具有重要的实证含义。**它表明，该算法所筛选出的股票簇，其内部在风格因子的暴露上具有更强的同质性与显著性。同时，基于该簇构建的多空组合，实现了对市场共性风格风险更彻底的对冲与剥离，从而更纯粹地捕捉到了由簇内特有交互效应产生的阿尔法。这种共性规律的强化与“噪音”的降低意味着，该股票簇构成了一个内部动力学更为一致、边界更为清晰的样本空间。在此优化后的子空间内进行分域建模，能够获得更具鉴别力的特征规则与更稳健的样本外预测性能，从而为后续的精准预测或投资组合构建提供结构化的优势。**因此，我们将首先尝试将面板树的训练方式进行微调，并进一步测试微调后的分域结果对于分域训练的提升。**

我们首先介绍改造后的面板树。具体的改造分两步骤：

Step1—模型预热阶段：在面板树的前十个轮次中，我们不加入任何改动，以起到基础的分域作用，且保持面板树分域的平衡性。

Step2—筛选下的优化阶段：从第十一个叶子开始，我们采用二次权重优化的形式，筛选掉部分权重较小的叶子，以提高每个最终分裂出叶子的作用。具体来说，假设当前待分裂的**节点**为n，其包含的股票样本集合为J_n。设当前所有**叶节点**的集合为L，每个叶节点$l \in L$对应一个市值加权组合，其收益率为R_l。所有叶节点在 T 期内的收益率构成矩阵$\boldsymbol{R} \in R^{T \times |L|}$。

对于每个候选切分 c，按以下步骤评估其质量：

1）生成临时叶节点收益：

将划分得到的左右子集分别构建为新的市值加权组合，计算其收益率序列，得到两个新的收益向量$r_L, r_R \in R^T$。

2）构造临时收益矩阵R' (c)：

创建一个临时的叶节点收益矩阵$R'(c)$，其中原节点n对应的旧叶节点收益被移除。新的左、右叶节点收益向量r_L和r_R被加入。

3）权重分配与叶子结点筛选：

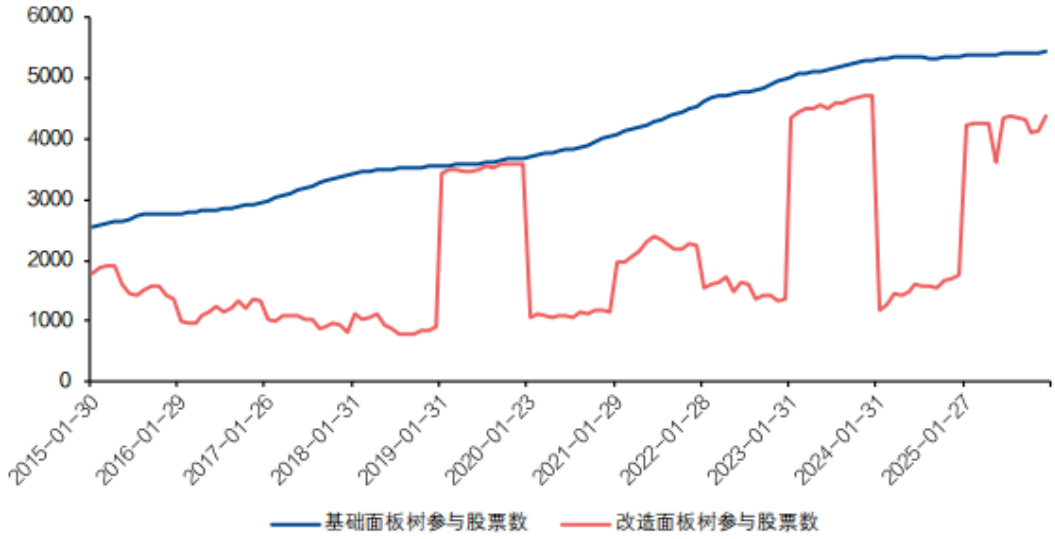
不同于前序模型的事，我们对每个集合，执行逐步纳入筛选。最终得到筛选后的节点子集，记为$L^{\top}(c)$。我们进一步使用筛选后的节点集合$L^{\top}(c)$对应的收益矩阵$R^{\top}(c)$，计算得到新的最优权重w^{*}，并计算其构建组合的夏普比率平方$(SR)^2(c)$。该候选切分c的最终评价指标即为$(SR)^2(c)$。算法将选择使$(SR)^2(c)$**最大化**的候选切分作为当前节点n的最优分裂规则。

综上，此改造的核心在于通过分阶段优化与筛选来评估分裂，确保了评估**是基于一个更简洁、更高效、更具实践性的对冲组合进行的。**其余的部分与之前的训练模式一致。

在得到改造后的训练结果之后，我们首先展示改造前后在测试集范围内参与计算的股票数目差异，即权重不为0的股票数目统计。从下图中可以明显看出，基于改造后的面板树模型在测试集当中，每期参

与的股票数目各不相同，且在时序上有着较大起伏：对于部分参与股票数目较小的时段，其主要是由于部分叶子中包含大量的股票样本，且该叶子的权重较低，这类叶子可以被认定为不具备明显风格特质的股票，因此在改造后权重被压缩为0，进而影响股票数目和面板树结构。

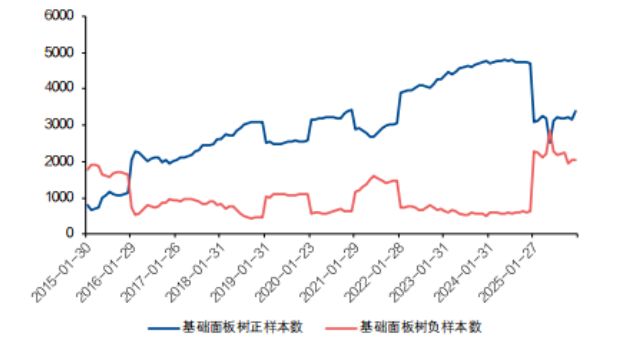
图11、测试集参与计算的股票数目统计（单位：个）



数据来源：wind，聚源，兴业证券经济与金融研究院整理

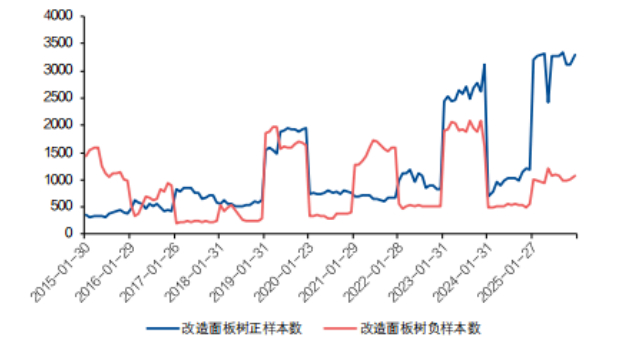
其次，我们展示基础面板树和改造面板树在正负样本上的差异，具体如下图。从展示中可以明显看出，在基础面板树当中，正样本权重的股票数目远高于负样本的股票数目，这是由于从历史数据上看，市场整体处于上涨趋势中，因此做多绝大多数的股票可以使得整体的夏普比率较高。但是这样的分域结果其实并不利于后续的训练：正样本个数太多的情况下，其训练得到的结果可能和全域训练结果接近。**在改造结果中，正负样本数得到了极大程度的平衡，这有利于后续的分域训练。**

图12、测试集参与计算的股票数目正负统计—基础面板树（单位：个）



数据来源：wind，聚源，兴业证券经济与金融研究院整理

图13、测试集参与计算的股票数目正负统计—改造面板树（单位：个）



数据来源：wind，聚源，兴业证券经济与金融研究院整理

最后，我们展示改造前后得到的预测集的组合以及绩效表现。从组合的绩效表现上，改造面板树的组合夏普比率相对较高，由之前的1.52提升至1.58，且收益回撤比也有之前的1.76提升至2.62，整体而言

由于参与的股票数目降低，组合的“锐度”相对得到提升。

图14、面板树测试集组合净值—改造前后



数据来源：wind，聚源，兴业证券经济与金融研究院整理

表7、面板树测试集组合表现统计—改造前后

	年化收益率	年化波动率	收益风险比	最大回撤	收益回撤比	月度胜率
基础面板树	9.41%	6.21%	1.52	5.33%	1.76	64.66%
改造面板树	11.38%	7.20%	1.58	4.35%	2.62	64.66%

数据来源：wind，聚源，兴业证券经济与金融研究院整理

4.2 基于代表域的分域训练模型

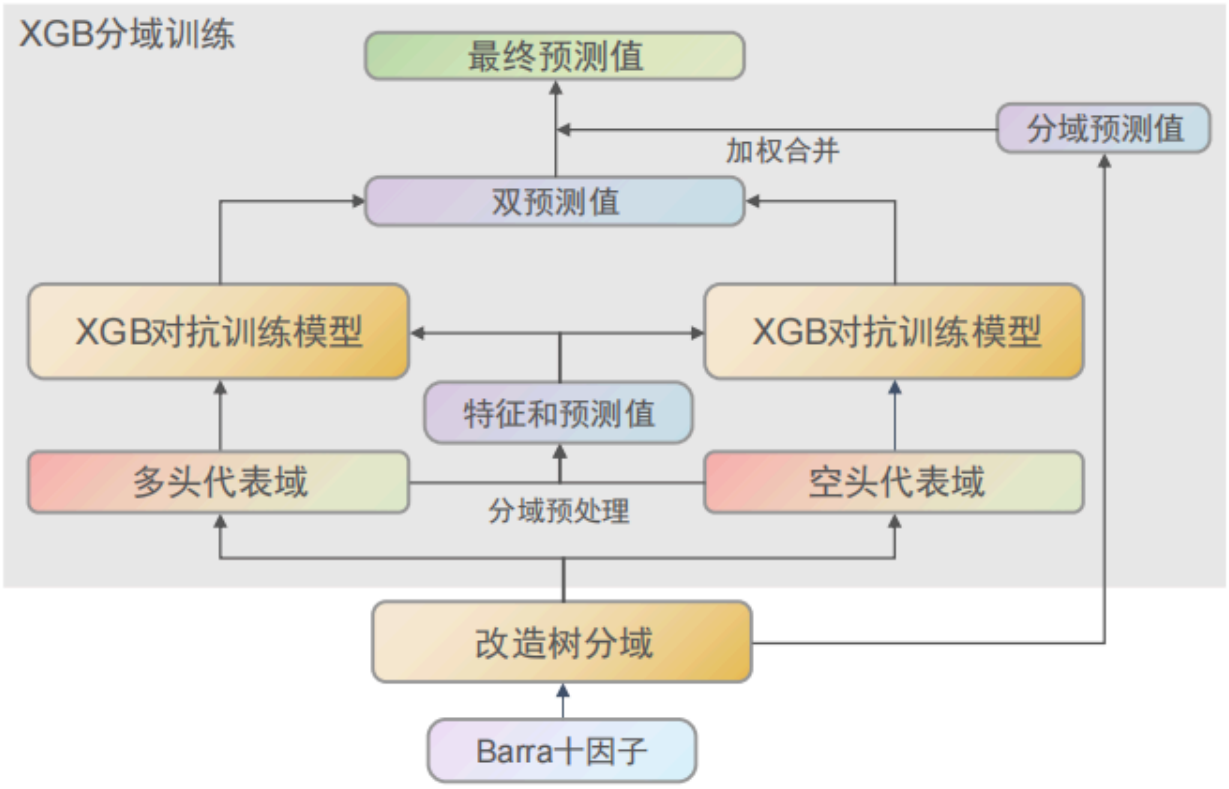
在得到改造后的面板树结果之后，我们再次采用前序的XGB分域训练模式，以类似的形式进行训练。与之前不同的是，在本节中我们的训练样本不再涵盖全样本集合，而是在每年面板树训练结束之后，训练集对应的权重非零样本中的正负样本。与上述训练不同的主要体现在以下Step1和Step3中：

Step1—构建多头代表域和空头代表域：我们根据训练集的分域结果，将叶子权重按照正负分为两部分。即在全样本集合内，基于每个叶子权重的正负号，将权重为正的叶子中的所有股票纳入多头代表域，将权重为负的叶子中的所有股票纳入空头代表域，**同时在训练中丢弃权重为0的样本。**

Step2—分域训练与结果合并：得到特征和Label之后，我们以不同的训练数据进行XGB对抗训练。训练流程按照前序文章的Kfold形式进行（详见报告《基于树模型的分组优化与风格约束改进—机器学习系列七》）。由此，我们分别训练得到两组针对全市场的预测值。之后，我们进一步引入面板树的预测数据，即在预测集部分每期每只股票的所属叶子标签。由于叶子权重在样本外保持不变，我们对于两个预测值采用调整加权方式合并：对于预测集被标记为正叶子权重的样本，将多头代表域训练得到的预测值

提升50%，反之亦然，若预测属于0权重的样本，则该样本的预测值不做调整。最后两个预测值加和得到最终预测值，即因子值。

图15、XGB 分域训练框架—改造面板树



数据来源：兴业证券经济与金融研究院整理

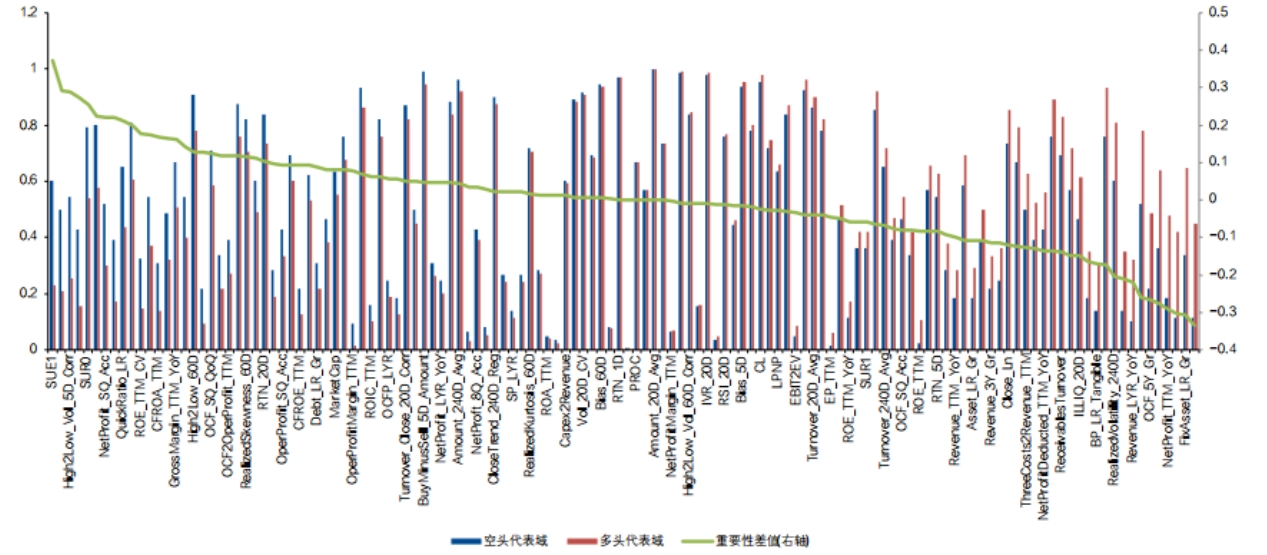
在确定好模型训练步骤后，我们以年度为单位，每个年末根据2009年至今的数据作为训练集，通过上述步骤进行训练得到模型，并以未来一年内的数据作为预测集预测得到Alpha因子值，并以年度为单位进行重新训练。在本章的预测对象上，我们基于未来10个交易日收益率进行训练，记为repDomainXGB。

4.3 改造分域训练模型表现统计

在展示因子有效性之前，我们先以2024年年底训练的模型为例，展示两个分域结果下的模型差异。

具体来说，我们首先展示两个子模型的特征重要性指标。具体来说，我们按照差值（空头模型减去多头模型）降序排序得到的两个模型各个特征的重要性排序值，以及两者的差异。从图中可以看出，两个模型在训练中使用的特征差异性较大，**在空头样本域中，模型倾向于更多地选择超预期、质量等指标，其在风格统计中也可以看出：空头域更倾向于选择基本面指标，如质量和成长类。而在多头样本域中，模型倾向于更多地选择低波，低估值等指标。**

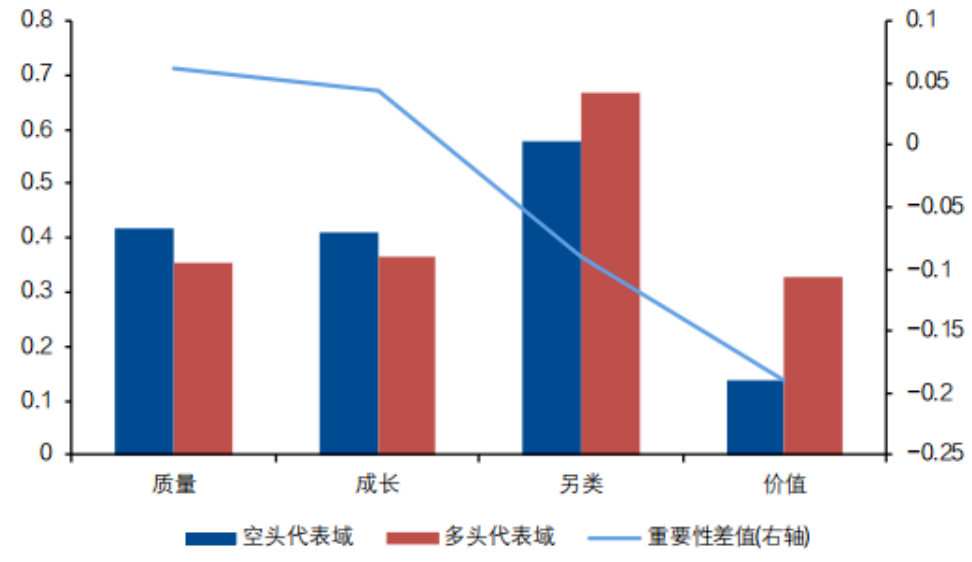
图16、多头代表域和空头代表域模型的特征重要性差异



数据来源：wind，聚源，兴业证券经济与金融研究院整理

进一步，我们筛选了重要性差值绝对值在15%以上特征后，按特征类别进行统计的结果。**从测试结果上看，空头样本域的股票可能已过度反应负面信息。此时投资者更关注：超预期或高质量公司，超预期和质量因子可能触发反转（价值回归）。而多头样本域中的股票已累积较大涨幅，因此模型选择更注重低波动股票或估值偏低，符合“动量中的防御”逻辑。**

图17、多头代表域和空头代表域大类因子差异统计



数据来源：wind，聚源，兴业证券经济与金融研究院整理

我们进一步展示基础、改造分域因子和基准模型（即前序章节的XGB模型）的回测结果：首先是Rank IC测试结果：从测试结果上看，改造分域因子的表现相对优秀，其全市场周度测试Rank IC均值约为0.123，IC IR约为1.004，表现出极强的稳定性，但同样的，在全市场范围测试相对基准模型并未明显

提升；在不同股票池内的测试中，改造分域训练因子的表现更加优秀，且相对基础分域模型有一定程度的提升：以沪深300内的测试结果为例，其因子Rank IC均值为0.077；此外，分域训练因子在中证500和中证1000的回测表现中同样存在提升，因子Rank IC均值稳定在0.094至0.11左右，相对基准和基础分域因子均有一定提升。

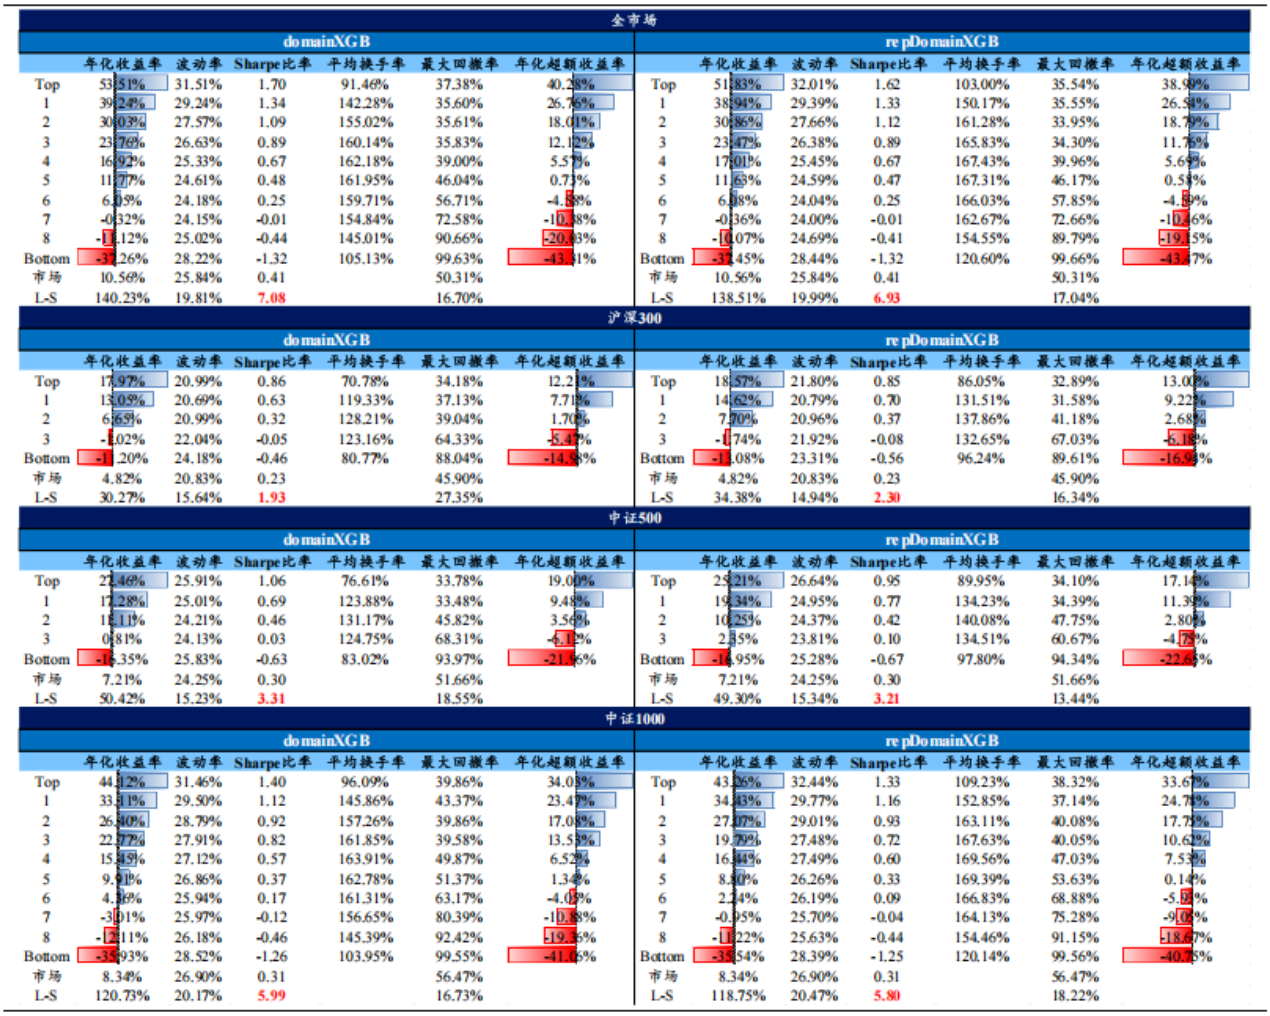
表8、改造分域训练模型 Rank IC 测试结果

股票池	因子名称	平均值	标准差	IC_IR
全市场	domainXGB	0.122	0.121	1.006
	repDomainXGB	0.123	0.123	1.004
	stylePenXGB	0.124	0.120	1.040
沪深 300	domainXGB	0.076	0.162	0.467
	repDomainXGB	0.077	0.150	0.510
	stylePenXGB	0.067	0.151	0.440
中证 500	domainXGB	0.095	0.137	0.691
	repDomainXGB	0.094	0.132	0.709
	stylePenXGB	0.091	0.122	0.744
中证 1000	domainXGB-10D	0.113	0.128	0.879
	repDomainXGB	0.114	0.129	0.886
	stylePenXGB	0.109	0.122	0.891

数据来源：wind，聚源，兴业证券经济与金融研究院整理

进一步，我们展示分位数组合的测试结果：从测试结果上看，在各个股票池的测试范围内，改造分域训练的因子repDomainXGB相对基准因子均有明显提升，尤其是在多头组上，但相对基准模型没有明显提升。

图18、改造分域训练模型分位数组合测试结果



全市场

domainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	53.51%	31.51%	1.70	91.46%	37.38%	40.28%
1	39.24%	29.24%	1.34	142.28%	35.60%	26.76%
2	30.03%	27.57%	1.09	155.02%	35.61%	18.01%
3	23.76%	26.63%	0.89	160.14%	35.83%	12.12%
4	16.92%	25.33%	0.67	162.18%	39.00%	5.57%
5	11.77%	24.61%	0.48	161.95%	46.04%	0.73%
6	6.05%	24.18%	0.25	159.71%	56.71%	-4.88%
7	-0.32%	24.15%	-0.01	154.84%	72.58%	-10.38%
8	-11.12%	25.02%	-0.44	145.01%	90.66%	-20.03%
Bottom	-37.26%	28.22%	-1.32	105.13%	99.63%	-43.31%
市场	10.56%	25.84%	0.41		50.31%	
L-S	140.23%	19.81%	7.08		16.70%	

repDomainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	51.83%	32.01%	1.62	103.00%	35.54%	38.99%
1	38.94%	29.39%	1.33	150.17%	35.55%	26.58%
2	30.86%	27.66%	1.12	161.28%	33.95%	18.79%
3	23.47%	26.38%	0.89	165.83%	34.30%	11.76%
4	17.01%	25.45%	0.67	167.43%	39.96%	5.69%
5	11.63%	24.59%	0.47	167.31%	46.17%	0.58%
6	6.08%	24.04%	0.25	166.03%	57.85%	-4.89%
7	-0.36%	24.00%	-0.01	162.67%	72.66%	-10.46%
8	-10.07%	24.69%	-0.41	154.55%	89.79%	-19.15%
Bottom	-37.45%	28.44%	-1.32	120.60%	99.66%	-43.47%
市场	10.56%	25.84%	0.41		50.31%	
L-S	138.51%	19.99%	6.93		17.04%	

沪深300

domainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	17.97%	20.99%	0.86	70.78%	34.18%	12.21%
1	13.05%	20.69%	0.63	119.33%	37.13%	7.71%
2	6.65%	20.99%	0.32	128.21%	39.04%	1.70%
3	-1.02%	22.04%	-0.05	123.16%	64.33%	-5.47%
Bottom	-11.20%	24.18%	-0.46	80.77%	88.04%	-14.58%
市场	4.82%	20.83%	0.23		45.90%	
L-S	30.27%	15.64%	1.93		27.35%	

repDomainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	18.57%	21.80%	0.85	86.05%	32.89%	13.00%
1	14.62%	20.79%	0.70	131.51%	31.58%	9.22%
2	7.70%	20.96%	0.37	137.86%	41.18%	2.68%
3	-1.74%	21.92%	-0.08	132.65%	67.03%	-6.18%
Bottom	-11.08%	23.31%	-0.56	96.24%	89.61%	-16.95%
市场	4.82%	20.83%	0.23		45.90%	
L-S	34.38%	14.94%	2.30		16.34%	

中证500

domainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	27.46%	25.91%	1.06	76.61%	33.78%	19.00%
1	17.28%	25.01%	0.69	123.88%	33.48%	9.48%
2	10.11%	24.21%	0.46	131.17%	45.82%	3.56%
3	0.81%	24.13%	0.03	124.75%	68.31%	-6.12%
Bottom	-16.35%	25.83%	-0.63	83.02%	93.97%	-21.96%
市场	7.21%	24.25%	0.30		51.66%	
L-S	50.42%	15.23%	3.31		18.55%	

repDomainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	25.21%	26.64%	0.95	89.95%	34.10%	17.14%
1	19.34%	24.95%	0.77	134.23%	34.39%	11.39%
2	10.25%	24.37%	0.42	140.08%	47.75%	2.80%
3	2.35%	23.81%	0.10	134.51%	60.67%	-4.75%
Bottom	-14.95%	25.28%	-0.67	97.80%	94.34%	-22.65%
市场	7.21%	24.25%	0.30		51.66%	
L-S	49.30%	15.34%	3.21		13.44%	

中证1000

domainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	44.12%	31.46%	1.40	96.09%	39.86%	34.03%
1	33.11%	29.50%	1.12	145.86%	43.37%	23.47%
2	26.40%	28.79%	0.92	157.26%	39.86%	17.08%
3	22.27%	27.91%	0.82	161.85%	39.58%	13.53%
4	15.45%	27.12%	0.57	163.91%	49.87%	6.52%
5	9.91%	26.86%	0.37	162.78%	51.37%	1.34%
6	4.36%	25.94%	0.17	161.31%	63.17%	-4.03%
7	-3.01%	25.97%	-0.12	156.65%	80.39%	-10.88%
8	-12.11%	26.18%	-0.46	145.39%	92.42%	-19.36%
Bottom	-35.93%	28.52%	-1.26	103.95%	99.55%	-41.06%
市场	8.34%	26.90%	0.31		56.47%	
L-S	120.73%	20.17%	5.99		16.73%	

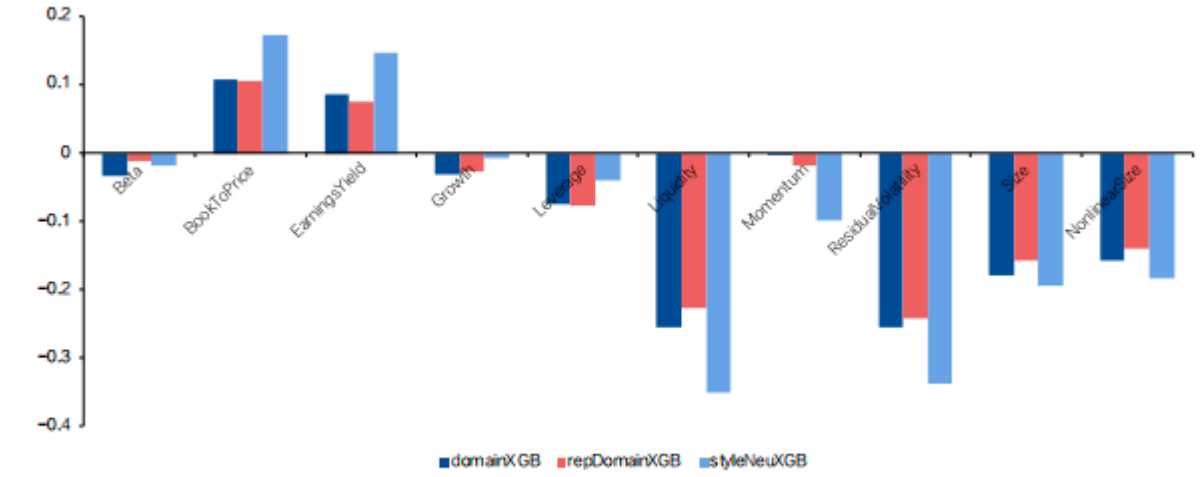
repDomainXGB

	年化收益率	波动率	Sharpe比率	平均换手率	最大回撤率	年化超额收益率
Top	43.26%	32.44%	1.33	109.23%	38.32%	33.67%
1	34.43%	29.77%	1.16	152.85%	37.14%	24.78%
2	27.07%	29.01%	0.93	163.11%	40.08%	17.73%
3	19.79%	27.48%	0.72	167.63%	40.05%	10.62%
4	16.44%	27.49%	0.60	169.56%	47.03%	7.53%
5	8.80%	26.26%	0.33	169.39%	53.63%	0.14%
6	2.24%	26.19%	0.09	166.83%	68.88%	-5.98%
7	-0.95%	25.70%	-0.04	164.13%	75.28%	-9.05%
8	-11.22%	25.63%	-0.44	154.46%	91.15%	-18.67%
Bottom	-35.54%	28.39%	-1.25	120.14%	99.56%	-40.75%
市场	8.34%	26.90%	0.31		56.47%	
L-S	118.75%	20.47%	5.80		18.22%	

数据来源：wind，聚源，兴业证券经济与金融研究院整理

我们进一步测试三个因子和风格因子的相关系数。从下图中可以明显看出：**基于面板树分域训练得到的因子和Barra十个风格因子的相关系数相对基准出现明显降低，尤其是在常见的风格中。**比如在市值、流动性和特质性波动率这三类风格中，基准模型与风格因子的相关系数大多在-0.2至-0.35左右。分域因子，尤其是改造分域模型因子与风格因子的相关系数降低较多，在流动性和特质性波动率上的相关系数降低至-0.22至-0.24左右。

图19、改造分域训练模型与 Barra 风格因子的相关系数



数据来源：wind，聚源，兴业证券经济与金融研究院整理

5、分域训练下的指数增强测试

5.1 改进方法总结

在上文中，我们在前文XGB对抗训练的基础上，通过引入面板树的概念对训练集合进行了全集和局部集的非线性分域，并进一步引入分域训练框架得到预测值。从单因子测试上看，**分域训练的因子具备风格相关性降低、股票池内有效性提升的特点。**

在本节中，我们尝试针对上述因子进行增强策略测试。我们首先测试各个因子的相关性，具体如下。从测试结果上看，基准因子和两种改进模型的相关性相对较低，维持在75%左右，这体现出改进方案与基准的差异性；此外，两类分域训练因子的相关系数也相对较低。

图20、各个 XGB 因子间相关性

	domainXGB	repDomainXGB	stylePenXGB
domainXGB		0.833	0.753
repDomainXGB	0.833		0.734
stylePenXGB	0.753	0.734	

数据来源：wind，聚源，兴业证券经济与金融研究院整理

基于上述因子，我们在下文中进行针对沪深300、中证500和中证1000的增强测试，进一步探究因子的表现以及优劣。对于各个增强测试，我们采用相似的约束条件进行回测，具体设定如下：

- 个股权重偏离：个股相对基准权重偏离±1.5%/1.0%/0.5%；
- 行业权重偏离：中信行业相对基准权重偏离±2.0%/1.5%/1.0%；
- 风格暴露偏离：风格因子Size和Beta相对基准偏离±0.2/0.15/0.1倍标准差；
- 成分股约束：成分股个数占比大于80%；
- 换手率约束：调仓双边换手率小于40%/60%/60%；
- 回测设定：周度调仓，回测区间上我们分别测试2020年至2025年10月底（记为近期），以及2015年初至2025年10月底（记为长期）；
- 样本空间：剔除当期不在市、特殊处理以及涨跌停的股票；
- 交易成本：买入千分之一，卖出千分之二，共计千分之三。

5.2 改造分域训练模型表现统计

在本节中，我们首先针对三个因子进行沪深300指数增强策略测试。我们首先展示各个因子近期以来（2020年以来）的增强测试表现。我们的约束条件如下：

- 个股权重偏离：个股相对基准权重偏离±1.5%；
- 行业权重偏离：中信行业相对基准权重偏离±2.0%；
- 风格暴露偏离：风格因子Size和Beta相对基准偏离±0.2倍标准差；
- 换手率约束：调仓双边换手率小于40%；

首先是近期表现的回测结果。以repDomainXGB为例，策略的平均持仓股票数目约为58只。从测试表现上看，无论是基础分域模型还是改造分域模型，其整体的策略表现均明显战胜基准XGB模型，其年化超额收益率在8-10%左右，尤其是repDomainXGB因子，相对净值的年化收益率约为10%，收益波动比约为1.6，超额最大回撤约为5.6%，收益回撤比为1.83，表现出较好的增强效果。

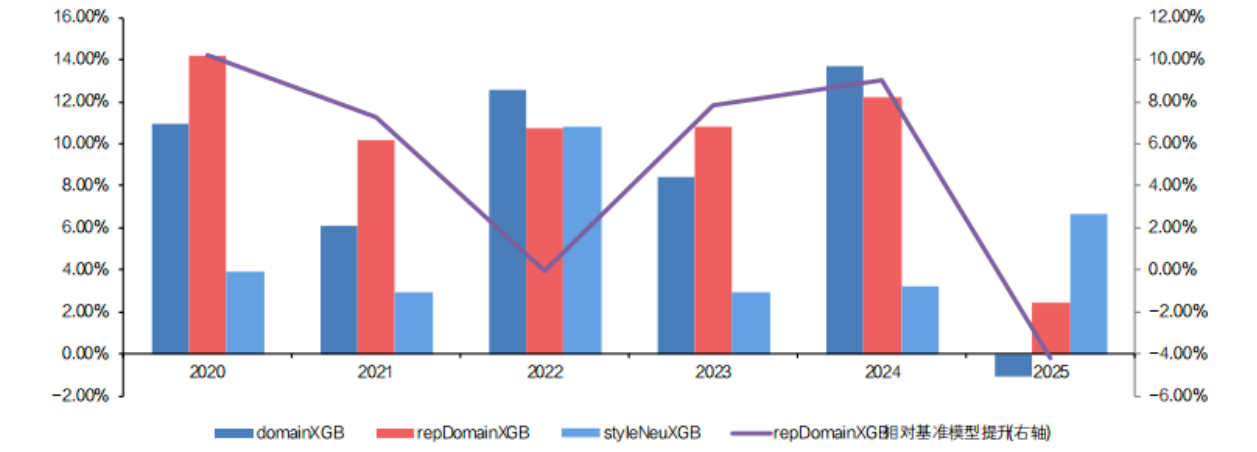
表9、各类 XGB 复合因子沪深 300 增强绩效表现—近期回测

	名称	年化收益率	年化波动率	收益波动比	最大回撤率	收益回撤比
策略表现	基准	1.96%	18.70%	0.10	45.60%	0.04
	domainXGB	10.84%	19.33%	0.56	30.51%	0.36
	repDomainXGB	12.58%	19.51%	0.65	27.09%	0.46
	stylePenXGB	7.32%	19.58%	0.37	40.42%	0.18
相对表现	domainXGB	8.58%	6.43%	1.34	7.84%	1.09
	repDomainXGB	10.34%	6.45%	1.60	5.64%	1.83
	stylePenXGB	5.19%	6.00%	0.87	8.03%	0.65

数据来源：wind，聚源，兴业证券经济与金融研究院整理

分年度上看，repDomainXGB在各个年度基本稳定战胜基准，且在部分年份相对基准有着近10%左右的提升。

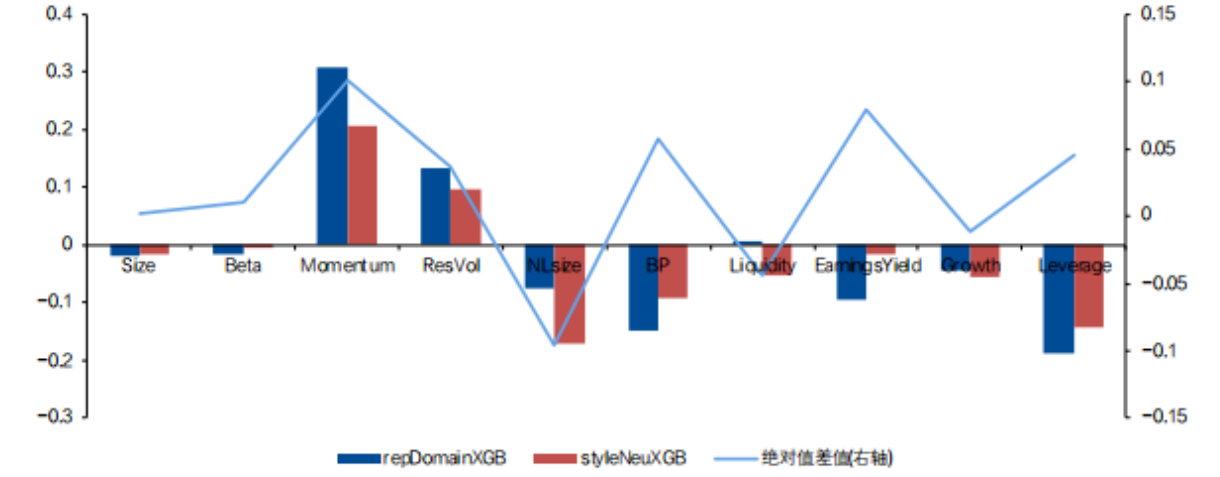
图21、各类 XGB 复合因子沪深 300 增强分年度超额收益—近期回测



数据来源：wind，聚源，兴业证券经济与金融研究院整理

从Barra风格暴露情况上看，分域训练的repDomainXGB策略主要在动量、低估值上相对基准模型有较高的暴露，在常见的如非线性市值和流动性上的暴露有所降低。

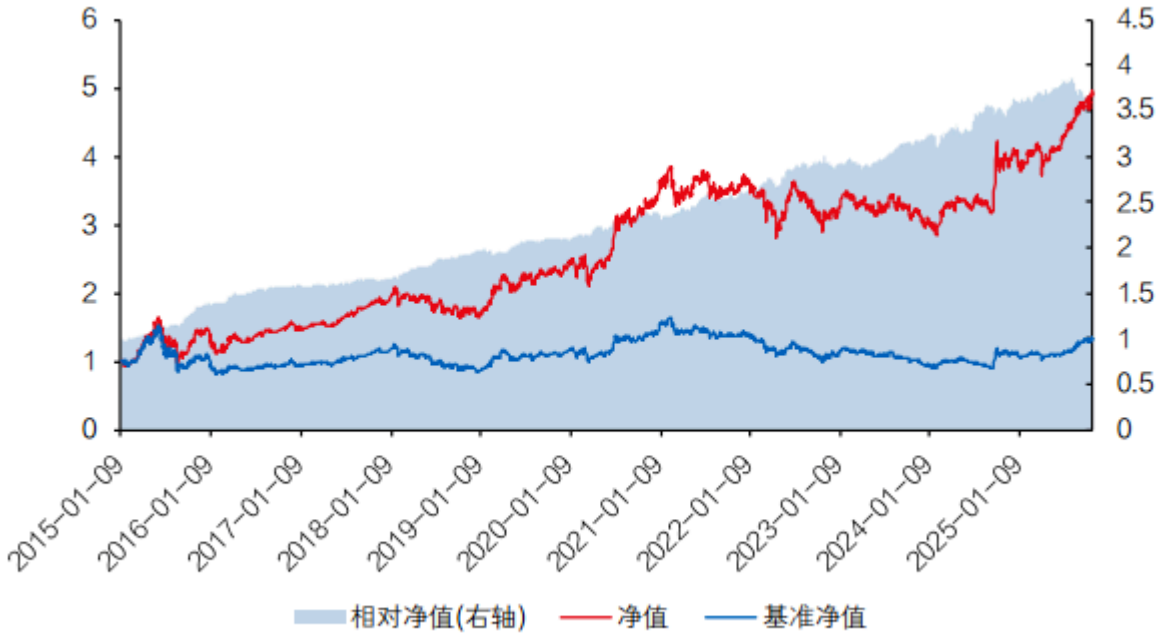
图22、各类 XGB 复合因子沪深 300 增强风格暴露统计—近期回测



数据来源：wind，聚源，兴业证券经济与金融研究院整理

最后，我们以repDomianXGB因子作为Alpha，以同样的约束条件进行长期增强测试，即从2015年起至回测结束日的表现。从多空净值以及分年度统计结果上看，该因子表现十分稳定，全时段年化超额收益率约为12.8%，跟踪误差控制在6.0%左右，超额夏普比率为2.14，最大回撤为5.7%，且除2025年以来，其余年份的最大回撤均小等于5%，月度胜率为75%，周度胜率为63%，展示出较好的稳定性。

图23、repDomainXGB 因子沪深 300 增强测试净值



数据来源：wind，聚源，兴业证券经济与金融研究院整理

表10、repDomainXGB 因子沪深 300 增强相对净值分年度统计结果

	年化收益率	年化波动率	收益风险比	最大回撤	收益回撤比	月度胜率	周度胜率
2015	39.4%	7.5%	5.26	2.76%	14.28	75.0%	71.2%
2016	14.7%	5.2%	2.81	2.50%	5.85	84.6%	58.5%
2017	3.9%	4.8%	0.82	3.49%	1.13	61.5%	50.9%
2018	19.2%	4.0%	4.76	1.50%	12.80	84.6%	77.4%
2019	6.2%	3.6%	1.70	3.17%	1.96	53.8%	57.4%
2020	13.7%	6.6%	2.08	3.54%	3.86	76.9%	67.9%
2021	10.0%	6.7%	1.51	4.23%	2.38	61.5%	64.2%
2022	11.5%	7.4%	1.56	4.47%	2.57	69.2%	52.8%
2023	10.5%	5.0%	2.10	4.06%	2.58	69.2%	66.0%
2024	12.0%	7.3%	1.65	5.01%	2.39	69.2%	59.3%
2025	3.0%	6.3%	0.47	5.65%	0.53	63.6%	52.3%
全时段	**12.8%**	**6.0%**	**2.14**	**5.65%**	**2.27**	**75.4%**	**62.8%**

数据来源：wind，聚源，兴业证券经济与金融研究院整理

注：2015 年开始时间为 2015 年 1 月 9 日，2025 年截至 2025 年 10 月 31 日

5.3 中证500指数增强测试

在本节中，我们针对三个因子进行中证500指数增强策略测试。我们首先展示各个因子近期以来（2020年以来）的增强测试表现。我们的约束条件如下：

- 个股权重偏离：个股相对基准权重偏离±1.0%；
- 行业权重偏离：中信行业相对基准权重偏离±1.5%；
- 风格暴露偏离：风格因子Size和Beta相对基准偏离±0.15倍标准差；
- 换手率约束：调仓双边换手率小于60%；

首先是近期表现的回测结果。以repDomainXGB为例，策略的平均持仓股票数目约为100只。从测试表现上看，无论是基础分域模型还是改造分域模型，其整体的策略表现均明显战胜基准XGB模型，其年化超额收益率在11-12%左右，其中repDomainXGB因子相对净值的年化收益率约为11.5%，收益波动比约为1.7，超额最大回撤约为6.0%，相对domainXGB的策略有明显降低，收益回撤比为1.92，表现出较好的增强效果。

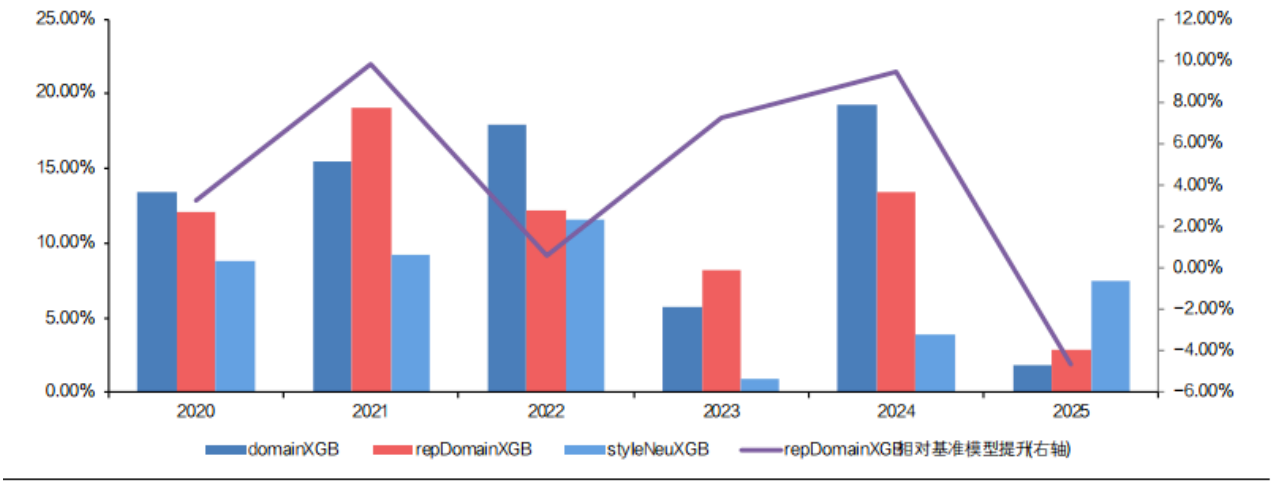
表11、各类 XGB 复合因子中证 500 增强绩效表现—近期回测

	名称	年化收益率	年化波动率	收益波动比	最大回撤率	收益回撤比
策略表现	基准	5.45%	21.25%	0.26	41.81%	0.13
	domainXGB	18.88%	21.66%	0.87	29.01%	0.65
	repDomainXGB	17.80%	22.07%	0.81	29.44%	0.60
	stylePenXGB	13.20%	21.46%	0.62	36.54%	0.36
相对表现	domainXGB	12.48%	6.91%	1.81	8.47%	1.47
	repDomainXGB	11.52%	6.79%	1.70	5.99%	1.92
	stylePenXGB	7.14%	6.10%	1.17	8.69%	0.82

数据来源：wind，兴业证券经济与金融研究院整理

分年度上看，repDomainXGB在各个年度基本稳定战胜基准，且在部分年份相对基准有着近10%左右的提升。

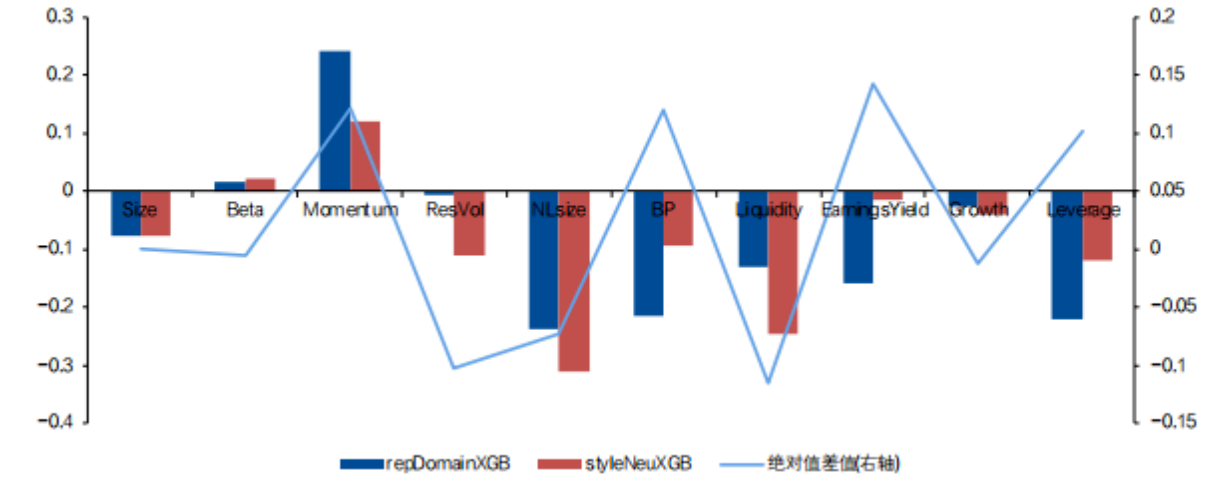
图24、各类 XGB 复合因子中证 500 增强分年度超额收益—近期回测



数据来源：wind，聚源，兴业证券经济与金融研究院整理

从Barra风格暴露情况上看，分域训练的repDomainXGB策略主要在动量、低估值上相对基准模型有较高的暴露，在常见的如特质性波动率、非线性市值和流动性上的暴露有所降低。

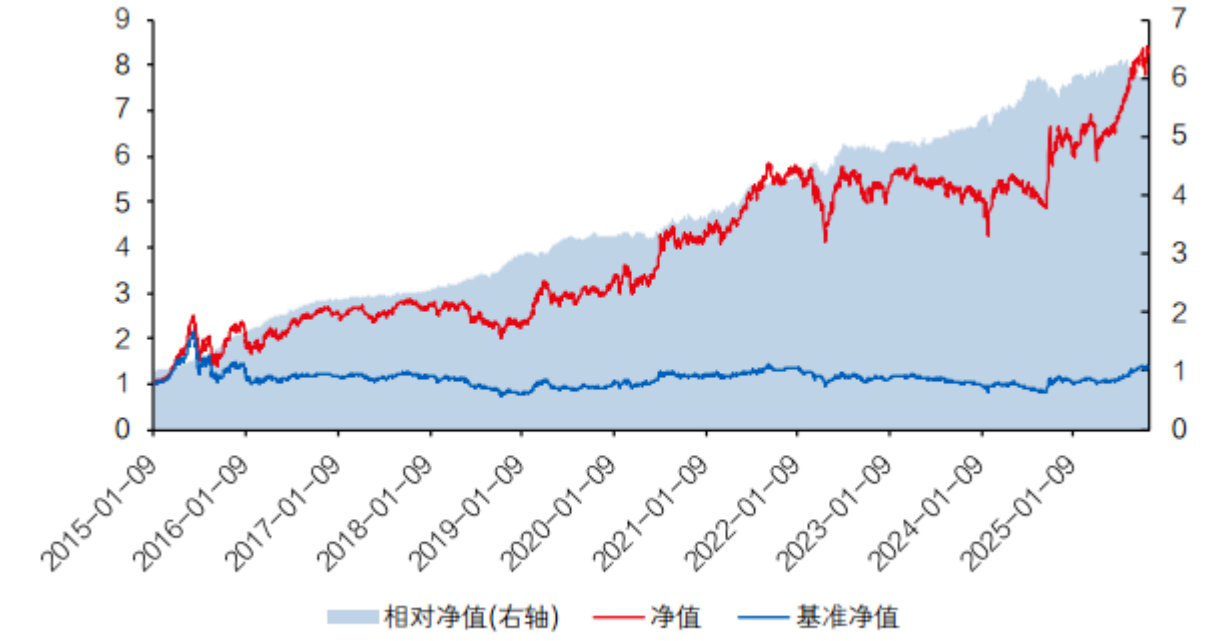
图25、各类 XGB 复合因子 300 增强风格暴露统计—近期回测



数据来源：wind，聚源，兴业证券经济与金融研究院整理

最后，我们以repDomianXGB因子作为Alpha，以同样的约束条件进行长期增强测试，即从2015年起至回测结束日的表现。从多空净值以及分年度统计结果上看，该因子表现十分稳定，全时段年化超额收益率约为17.5%，跟踪误差控制在6.5%左右，超额夏普比率为2.71，最大回撤为6.78%，且除2024和2025年以来，其余年份的最大回撤均小等于6%，月度胜率约为79%，周度胜率约为64%，展示出较好的稳定性。

图26、repDomainXGB 因子中证 500 增强测试净值



数据来源：wind，聚源，兴业证券经济与金融研究院整理

表 12、repDomainXGB 因子中证 500 增强相对净值分年度统计结果

	年化收益率	年化波动率	收益风险比	最大回撤	收益回撤比	月度胜率	周度胜率
2015	60.9%	9.2%	6.64	4.19%	14.53	83.3%	75.0%
2016	32.5%	5.0%	6.56	1.48%	21.95	84.6%	71.7%
2017	7.7%	5.2%	1.49	2.65%	2.90	76.9%	60.4%
2018	23.4%	4.8%	4.86	1.67%	14.04	76.9%	67.9%
2019	11.4%	4.1%	2.81	2.42%	4.70	84.6%	59.3%
2020	10.1%	6.4%	1.59	4.80%	2.11	76.9%	60.4%
2021	9.9%	7.4%	1.34	4.14%	2.39	53.8%	60.4%
2022	17.1%	6.9%	2.47	4.05%	4.21	61.5%	56.6%
2023	6.8%	4.9%	1.39	2.72%	2.51	69.2%	56.6%
2024	19.0%	8.5%	2.24	6.78%	2.80	76.9%	70.4%
2025	2.3%	6.4%	0.35	6.01%	0.38	54.5%	50.0%
全时段	**17.5%**	**6.5%**	**2.71**	**6.78%**	**2.58**	**78.5%**	**63.9%**

数据来源：wind，聚源，兴业证券经济与金融研究院整理
注：2015 年开始时间为 2015 年 1 月 9 日，2025 年截至 2025 年 10 月 31 日

5.4 中证1000指数增强测试

在本节中，我们针对三个因子进行中证1000指数增强策略测试。我们首先展示各个因子近期以来（2020年以来）的增强测试表现。我们的约束条件如下：

- 个股权重偏离：个股相对基准权重偏离±0.5%；
- 行业权重偏离：中信行业相对基准权重偏离±1.0%；
- 风格暴露偏离：风格因子Size和Beta相对基准偏离±0.1倍标准差；
- 换手率约束：调仓双边换手率小于60%；

首先是近期表现的回测结果。以repDomainXGB为例，策略的平均持仓股票数目约为190只。从测试表现上看，无论是基础分域模型还是改造分域模型，其整体的策略表现均明显战胜基准XGB模型，其年化超额收益率在14-16%左右，尤其是repDomainXGB因子，相对净值的年化收益率约为16%，收益波动比约为2.44，超额最大回撤约为6.3%，收益回撤比为2.54，表现出较好的增强效果。

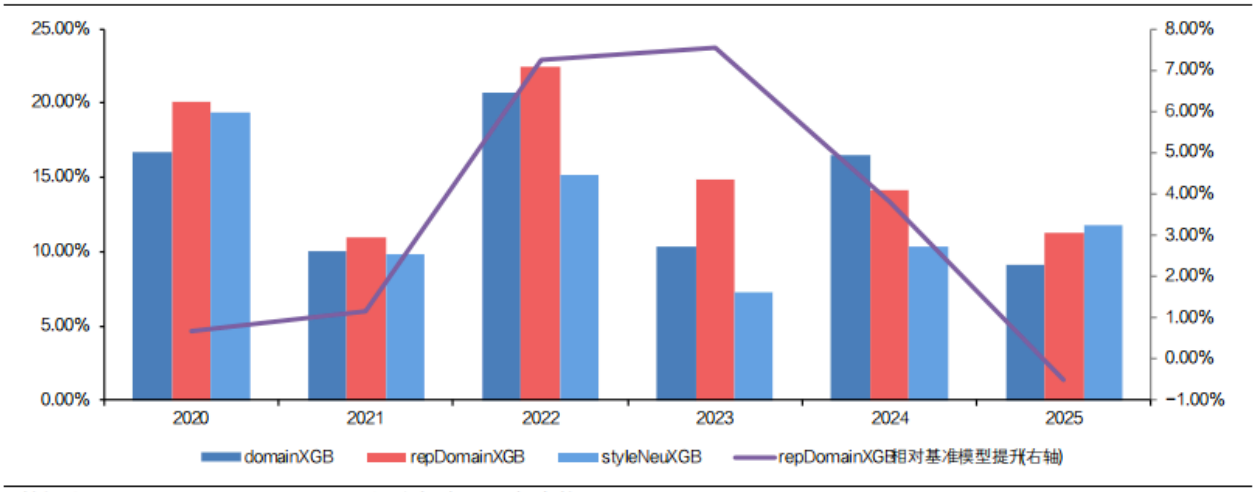
表13、各类 XGB 复合因子中证 1000 增强绩效表现—近期回测

	名称	年化收益率	年化波动率	收益波动比	最大回撤率	收益回撤比
策略表现	基准	4.82%	24.21%	0.20	46.71%	0.10
	domainXGB	19.95%	24.48%	0.81	33.22%	0.60
	repDomainXGB	21.67%	24.99%	0.87	33.15%	0.65
	stylePenXGB	18.26%	24.16%	0.76	36.49%	0.50
相对表现	domainXGB	14.25%	6.52%	2.19	9.35%	1.52
	repDomainXGB	16.02%	6.56%	2.44	6.32%	2.54
	stylePenXGB	12.60%	6.08%	2.07	7.93%	1.59

数据来源：wind，聚源，兴业证券经济与金融研究院整理

分年度上看，repDomainXGB在各个年度基本稳定战胜基准，且在部分年份相对基准有着近10%左右的提升。

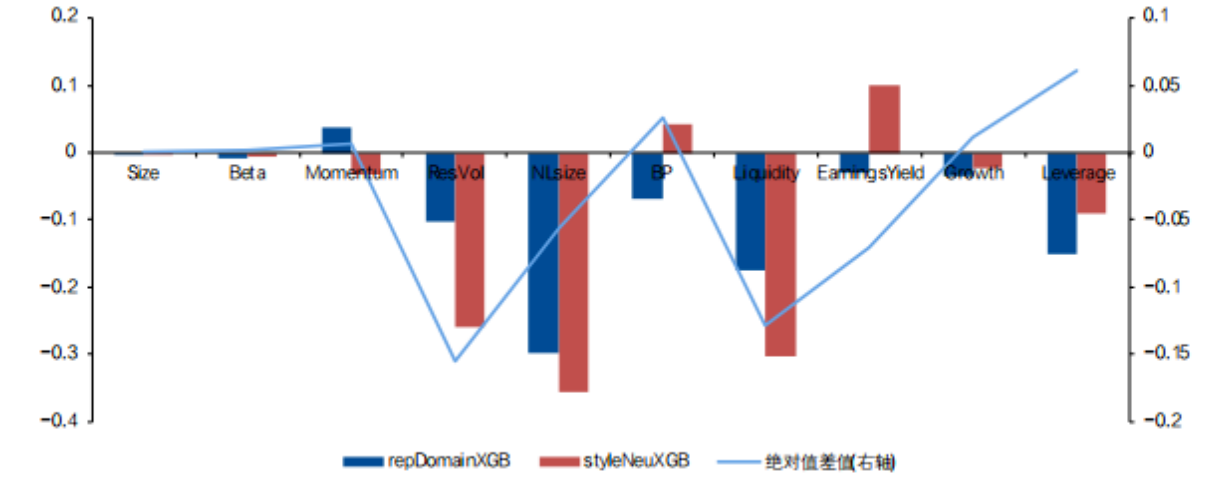
图27、各类 XGB 复合因子中证 1000 增强分年度超额收益—近期回测



数据来源：wind，聚源，兴业证券经济与金融研究院整理

从Barra风格暴露情况上看，分域训练的repDomainXGB策略主要在动量、低估值上相对基准模型有较高的暴露，在常见的如非线性市值和流动性上的暴露有所降低。

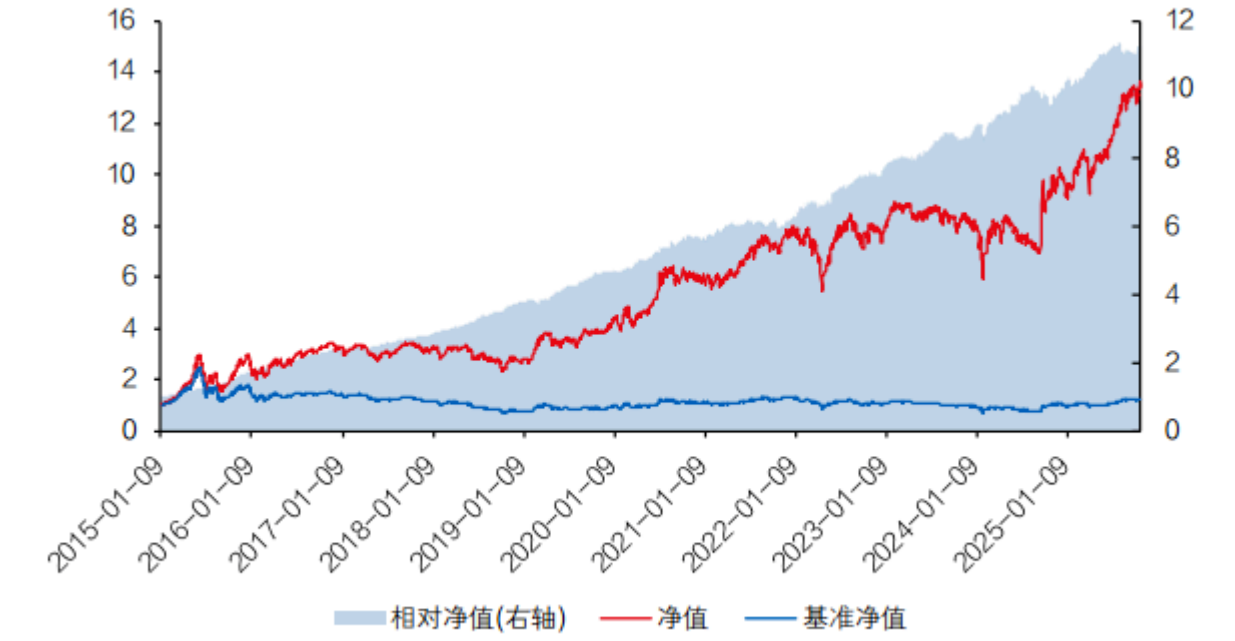
图28、各类 XGB 复合因子中证 1000 增强风格暴露统计—近期回测



数据来源：wind，聚源，兴业证券经济与金融研究院整理

最后，我们以repDomianXGB因子作为Alpha，以同样的约束条件进行长期增强测试，即从2015年起至回测结束日的表现。从多空净值以及分年度统计结果上看，该因子表现十分稳定，全时段年化超额收益率约为24.8%，跟踪误差控制在6.0%左右，超额夏普比率为4.02，最大回撤为6.2%，且除2024年以来，其余年份的最大回撤均小等于5%，月度胜率为82%，周度胜率为68%，展示出较好的稳定性。

图29、repDomainXGB 因子中证 1000 增强测试净值



数据来源：wind，聚源，兴业证券经济与金融研究院整理

表14、repDomainXGB 因子中证 1000 增强相对净值分年度统计结果

	年化收益率	年化波动率	收益风险比	最大回撤	收益回撤比	月度胜率	周度胜率
2015	66.9%	6.3%	10.67	1.91%	35.00	91.7%	86.5%
2016	38.0%	4.5%	8.46	2.08%	18.32	84.6%	75.5%
2017	21.1%	4.8%	4.40	1.53%	13.79	84.6%	67.9%
2018	34.5%	4.4%	7.83	1.10%	31.50	84.6%	77.4%
2019	19.9%	4.4%	4.54	2.31%	8.62	84.6%	63.0%
2020	16.4%	6.0%	2.72	3.32%	4.95	61.5%	64.2%
2021	11.7%	7.4%	1.58	5.91%	1.98	61.5%	60.4%
2022	21.2%	6.4%	3.32	3.08%	6.86	69.2%	58.5%
2023	12.7%	5.7%	2.23	2.52%	5.04	76.9%	60.4%
2024	15.0%	8.2%	1.84	6.17%	2.43	76.9%	64.8%
2025	16.4%	6.1%	2.69	2.89%	5.66	63.6%	59.1%
全时段	**24.1%**	**6.0%**	**4.02**	**6.17%**	**3.90**	**82.3%**	**68.3%**

数据来源：wind，聚源，兴业证券经济与金融研究院整理

注：2015 年开始时间为 2015 年 1 月 9 日，2025 年截至 2025 年 10 月 31 日

6、总结

本文中，我们突破传统的线性或规则分域的框架，创新性地将面板树模型与风格因子相结合，构建了一套动态、非线性的股票分域体系。通过采用局部域优化的方式对面板树进行改造，实现了对训练样本的智能化分域处理，并在此基础上建立了更精细的收益率预测模型。实证结果表明，该分域建模方法能有效捕捉市场异质性，为多空组合构建与因子优化提供了新的解决路径。

进一步测试显示，经改造后的分域训练模型在沪深300、中证500及中证1000等多个主要宽基指数上均表现出稳定的增强效果，验证了该框架在不同市场环境与市值板块中的适应性与稳健性。该研究不仅为量化选股提供了新的方法论工具，也为后续探索更复杂的非线性分域模型奠定了实践基础，具备较强的理论意义与实战价值。

在未来我们将继续深耕该领域，尝试做出更多有意义且具备创新性的研究。

风险提示：模型结果基于历史数据的测算，在市场环境转变时模型存在失效的风险

注：文中报告节选自兴业证券经济与金融研究院已公开发布研究报告，具体报告内容及相关风险提示等详见完整版报告。
证券研究报告：《基于风格因子的非线性分域训练研究—机器学习系列九》
对外发布时间：2026年1月27日
报告发布机构：兴业证券股份有限公司（已获中国证监会许可的证券投资咨询业务资格）

分析师：
郑兆磊
SAC执业证书编号：S0190520080006
E-mail: zhengzhaolei@xyzq.com.cn

陈子轩
SAC执业证书编号：S0190524120001
E-mail: chenzixuan@xyzq.com.cn

感谢实习生沈楚峰对本文作出的贡献。

更多量化最新资讯和研究成果，欢迎关注我们的微信公众平台（微信号：XYQuantResearch）！

往 期 链 接

基于树模型的分组优化与风格约束改进—机器学习系列七
MEGA-GRU：如何结合股票的时序、截面和关联信息——机器学习系列八



长按识别小程序码
进入 兴证研究小程序 阅读全文

自媒体信息披露与重要声明

使用本研究报告的风险提示及法律声明

兴业证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。

本报告仅供兴业证券股份有限公司（以下简称"本公司"）的客户使用，本公司不会因接收人收到本报告而视其为客户。本报告中的信息、意见等均仅供客户参考，不构成所述证券买卖的出价或征价邀请或要约，投资者自主作出投资决策并自行承担投资风险，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效，任何有关本报告的摘要或节选都不代表本报告正式完整的观点，一切须以本公司向客户发布的本报告完整版本为准。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐。客户应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求，必要时就法律、商业、财务、税收等方面咨询专家的意见。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本报告所载资料的来源被认为是可靠的，但本公司不保证其准确性或完整性，也不保证所包含的信息和建议不会发生任何变更。本公司并不对使用本报告所包含的材料产生的任何直接或间接损失或与此相关的其他任何损失承担任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌，过往表现不应作为日后的表现依据；在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告；本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的回报预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告的版权归本公司所有。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。未经授权的转载，本公司不承担任何转载责任。

在法律许可的情况下，兴业证券股份有限公司可能会持有本报告中提及公司所发行的证券头寸并进行交易，也可能为这些公司提供或争取提供投资银行业务服务。因此，投资者应当考虑到兴业证券股份有限公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。

投资评级说明

报告中投资建议所涉及的评级分为股票评级和行业评级（另有说明的除外）。评级标准为报告发布日后的 12 个月内公司股价（或行业指数）相对同期相关证券市场代表性指数的涨跌幅。其中：沪深两市以沪深 300 指数为基准；北交所市场以北证 50 指数为基准；新三板市场以三板成指为基准；香港市场以恒生指数为基准；美国市场以标普 500 或纳斯达克综合指数为基准。

行业评级：推荐-相对表现优于同期相关证券市场代表性指数；中性-相对表现与同期相关证券市场代表性指数持平；回避-相对表现弱于同期相关证券市场代表性指数。

股票评级：买入-相对同期相关证券市场代表性指数涨幅大于 15%；增持-相对同期相关证券市场代表性指数涨幅在 5%～15%之间；中性-相对同期相关证券市场代表性指数涨幅在-5%～5%之间；减持-相对同期相关证券市场代表性指数涨幅小于-5%；无评级-由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级。

免责声明

市场有风险，投资需谨慎。本平台所载内容和意见仅供参考，不构成对任何人的投资建议（专家、嘉宾或其他兴业证券股份有限公司以外的人士的演讲、交流或会议纪要等仅代表其本人或其所在机构之观点），亦不构成任何保证，接收人不应单纯依靠本资料的信息而取代自身的独立判断，应自主做出投资决策并自行承担风险。根据《证券期货投资者适当性管理办法》，本平台内容仅供兴业证券股份有限公司客户中的专业投资者使用，若您并非专业投资者，为保证服务质量、控制投资风险，请勿订阅或转载本平台中的信息，本资料难以设置访问权限，若给您造成不便，还请见谅。在任何情况下，作者及作者所在团队、兴业证券股份有限公司不对任何人因使用本平台中的任何内容所引致的任何损失负任何责任。

本平台旨在沟通研究信息，交流研究经验，不是兴业证券股份有限公司研究报告的发布平台，所发布观点不代表兴业证券股份有限公司观点。任何完整的研究观点应以兴业证券股份有限公司正式发布的报告为准。本平台所载内容仅反映作者于发出完整报告当日或发布本平台内容当日的判断，可随时更改且不予通告。

本平台所载内容不构成对具体证券在具体价位、具体时点、具体市场表现的判断或投资建议，不能够等同于指导具体投资的操作性意见。